Praktikum 1. Dari Dataset ke Model: Peta ML dalam Konteks Sensor

Dataset Real: UCI Air Quality

Praktikum ini memakai satu dataset real yaitu UCI Air Quality berisi 9.358 hourly averaged observations dari lima metal-oxide chemical sensors dan reference analyzer pada sebuah kota di Italia. Rekaman mencakup Maret 2004-Februari 2005. UCI mendokumentasikan adanya missing values dengan sentinel -200 serta evidence cross-sensitivity, concept drift, dan sensor drift. Pahami masing-masing atribut dengan mengakses https://archive.ics.uci.edu/dataset/360/air%2B

1A. Memuat Dataset dan Memastikan Sumber Data

Gunakan file lokal bila sudah tersedia. Jika belum ada, notebook dapat mengambil file dari URL GitHub. Pada tahap ini tujuan utamanya bukan membersihkan data, tetapi memastikan bahwa sumber, separator, jumlah kolom, dan beberapa baris pertama terbaca dengan benar.

Load dataset dari local drive atau URL

```
from pathlib import Path
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

LOCAL = Path('../data/AirQualityUCI.csv')
URL = (
    'https://raw.githubusercontent.com/PacktPublishing/'
    'Time-Series-Analysis-with-Python-Cookbook/refs/heads/main/'
    'datasets/Ch2/AirQualityUCI.csv'
)

source = LOCAL if LOCAL.exists() else URL
print('Sumber data:', source)

df_raw = pd.read_csv(source, sep=';')
df_raw = df_raw.dropna(axis=1, how='all')

print('Shape data mentah:', df_raw.shape)
display(df_raw.head())
```

Pemeriksaan	Hasil
Sumber yang dipakai (lokal/URL)	
Shape data	
Jumlah kolom	
Tiga nama kolom pertama	
Tiga nama kolom terakhir	

1B. Memahami Struktur: Baris, Kolom, Tipe Data, dan Waktu

Satu baris pada dataset ini merepresentasikan satu observasi rata-rata per jam. Kolom berisi waktu, hasil reference analyzer, respons beberapa sensor, serta kondisi lingkungan. Sebelum menghitung statistik, periksa tipe data. Angka yang masih dibaca sebagai object/string tidak boleh langsung dirata-ratakan.

Pemeriksaan struktur

```
df = df_raw.copy()

# Membentuk timestamp. Kode tetap aman jika Time sudah memakai ':'
time_text = (
    df['Time'].astype(str).str.strip()
      .str.replace('.', ':', regex=False)
)

df['datetime'] = pd.to_datetime(
    df['Date'].astype(str).str.strip() + ' ' + time_text,
    dayfirst=True,
    errors='coerce'
)

print('Shape:', df.shape)
print('\nDaftar kolom:')
print(df.columns.tolist())
print('\nTipe data:')
print(df.dtypes)
print('\nDatetime gagal diparse:', df['datetime'].isna().sum())
display(df.head())
```

Pertanyaan	Jawaban mahasiswa
Apa arti satu baris?	
Kolom waktu?	
Reference measurement?	
Sensor response?	
Kondisi lingkungan?	
Mengapa angka yang tersimpan sebagai object dapat menyebabkan error ketika dihitung mean?	

1C. Mengenali Sentinel Missing sebelum Menghitung Statistik

Dokumentasi dataset menggunakan nilai -200 sebagai penanda data tidak tersedia. Angka -200 bukan pengukuran fisik yang sebenarnya. Jika dibiarkan, nilai tersebut akan memengaruhi minimum, mean, standard deviation, histogram, dan grafik. Pertemuan ini belum membahas strategi imputation; kita hanya membuat analysis view agar statistik awal tidak menganggap sentinel sebagai data nyata.

Membandingkan data mentah dan analysis view

```
import numpy as np
```

```
# Pastikan kolom pengukuran menjadi numerik
numeric_cols = [
    c for c in df.columns
    if c not in ['Date', 'Time', 'datetime']
]

df[numeric_cols] = df[numeric_cols].apply(
    pd.to_numeric,
    errors='coerce'
)

sentinel_count = (df[numeric_cols] == -200).sum()
print('Jumlah sentinel -200 per kolom:')
display(sentinel_count[sentinel_count > 0].sort_values(ascending=False))

analysis = df.copy()
analysis[numeric_cols] = analysis[numeric_cols].replace(-200, np.nan)
missing_pct = (
    analysis[numeric_cols].isna().mean()
    .mul(100)
    .sort_values(ascending=False)
)

display(missing_pct.to_frame('missing_pct').head(10))
```

Kolom	Minimum sebelum	Minimum sesudah -200 -> NaN	Jumlah missing	Interpretasi
CO(GT)				
T				
RH				
PT08.S1(CO)				
NOx(GT)				

1. Mengapa kalimat "-200 adalah nilai terendah CO" salah secara semantik?

1D. Statistik Deskriptif: Min, Max, Range, Mean, Median, dan Standard Deviation

Statistik deskriptif merangkum data tanpa membangun model. Minimum dan maksimum menunjukkan rentang pengamatan, mean menunjukkan pusat berdasarkan seluruh nilai, median menunjukkan nilai tengah yang lebih tahan terhadap nilai ekstrem, sedangkan standard deviation memberi gambaran sebaran. Tidak ada satu ringkasan yang selalu paling baik; ringkasan dibaca bersama distribusi dan konteks variabel.

Membuat tabel statistik ringkas

```
summary = analysis[numeric_cols].agg(
    ['count', 'min', 'max', 'mean', 'median', 'std']
).T
summary['range'] = summary['max'] - summary['min']

# Atur urutan kolom agar mudah dibaca
summary = summary[
    ['count', 'min', 'max', 'range', 'mean', 'median', 'std']
```

```
]

display(summary.round(3))

# Contoh fokus pada beberapa variabel
focus = ['CO(GT)', 'PT08.S1(CO)', 'T', 'RH', 'AH']
display(summary.loc[focus].round(3))
```

Tugas interpretasi statistik:

- Cari variabel dengan range terbesar dan terkecil. Apakah range dapat langsung dibandingkan jika satuannya berbeda?
- Bandingkan mean dan median CO(GT). Jika berbeda cukup besar, apa kemungkinan bentuk distribusinya?
- Pilih satu sensor response dan jelaskan makna min, max, mean, median, dan std dengan kalimat, bukan hanya angka.

1E. Visualisasi: Melihat Bentuk, Waktu, Hubungan, dan Missingness

Grafik dipakai untuk melihat aspek yang sulit ditangkap oleh tabel. Histogram menjawab bentuk distribusi; boxplot membantu melihat pusat, kuartil, dan kandidat nilai ekstrem; time plot menunjukkan perubahan sepanjang waktu; scatterplot menunjukkan association dua variabel; bar chart missing-rate menunjukkan seberapa besar data hilang per kolom.

Empat visualisasi dasar

```
fig, axes = plt.subplots(2, 2, figsize=(12, 8))

# 1. Histogram CO(GT)
analysis['CO(GT)'].dropna().hist(
    bins=40, ax=axes[0,0], edgecolor='black'
)
axes[0,0].set_title('Distribusi CO(GT)')
axes[0,0].set_xlabel('CO(GT)')
axes[0,0].set_ylabel('Frekuensi')

# 2. Boxplot CO(GT)
analysis.boxplot(column='CO(GT)', ax=axes[0,1])
axes[0,1].set_title('Boxplot CO(GT)')
axes[0,1].set_ylabel('CO(GT)')

# 3. Time plot: 7 hari pertama yang valid
week = (
    analysis.dropna(subset=['datetime','CO(GT)'])
    .sort_values('datetime')
    .head(24 * 7)
)
axes[1,0].plot(week['datetime'], week['CO(GT)'])
axes[1,0].set_title('CO(GT) pada 7 Hari Awal')
axes[1,0].set_xlabel('Waktu')
axes[1,0].set_ylabel('CO(GT)')
axes[1,0].tick_params(axis='x', rotation=35)

# 4. Scatter sensor vs reference measurement
```

```
pair = analysis[['PT08.S1(CO)', 'CO(GT)']].dropna()
axes[1,1].scatter(
    pair['PT08.S1(CO)'], pair['CO(GT)'],
    s=8, alpha=0.3
)
axes[1,1].set_title('PT08.S1(CO) vs CO(GT)')
axes[1,1].set_xlabel('PT08.S1(CO)')
axes[1,1].set_ylabel('CO(GT)')

plt.tight_layout()
plt.show()
```

Visualisasi missing value

```
missing_nonzero = missing_pct[missing_pct > 0].sort_values()

plt.figure(figsize=(8, 4))
missing_nonzero.plot(kind='barh')
plt.xlabel('Missing (%)')
plt.ylabel('Kolom')
plt.title('Persentase Missing per Kolom')
plt.tight_layout()
plt.show()
```

1F. Membaca Grafik dan Menulis Interpretasi

Interpretasi yang baik memisahkan tiga hal: (1) bukti yang benar-benar terlihat pada data/grafik, (2) dugaan atau hipotesis penyebab, dan (3) hal yang belum dapat disimpulkan. Kalimat “PT08.S1(CO) cenderung meningkat ketika CO(GT) meningkat pada sampel ini” adalah deskriptif. Kalimat “sensor menyebabkan CO meningkat” tidak didukung oleh scatterplot.

Grafik	Pertanyaan yang harus dijawab
Histogram	Apakah distribusi simetris, miring, memiliki banyak puncak, atau ekor panjang?
Boxplot	Apakah terdapat kandidat nilai ekstrem? Apakah kandidat tersebut otomatis salah?
Time plot	Apakah nilai stabil sepanjang 7 hari? Kapan muncul puncak atau penurunan?
Scatterplot	Apakah dua variabel tampak berasosiasi? Linear, nonlinear, atau sangat menyebar?
Missing-rate	Kolom mana yang kehilangan data paling banyak dan mengapa hal ini perlu diperhatikan?

Diskusi kelompok (10 menit):

- Pilih satu grafik. Tuliskan satu temuan yang didukung, satu dugaan penyebab, dan satu kesimpulan yang belum boleh dibuat.
- Apakah mean saja cukup untuk memahami CO(GT)? Jelaskan dengan menghubungkan tabel statistik dan histogram.
- Jika dua sensor mempunyai range sangat berbeda, apakah angka range yang lebih besar berarti sensor itu lebih penting? Mengapa?

1G. Praktik Mini Mandiri

Pilih satu kolom numerik selain CO(GT). Lakukan empat langkah berikut: (1) tampilkan count, min, max, mean, median, std; (2) buat histogram; (3) buat boxplot; (4) tulis interpretasi 100-150 kata yang menjelaskan pusat, sebaran, kandidat nilai ekstrem, dan keterbatasan interpretasi. Gunakan bahasa deskriptif dan jangan membuat klaim kausal.