


## A. Tujuan dan Luaran

- Mengaudit dataset messy secara sistematis sebelum memperbaikinya.
- Mendeteksi missing, duplikasi, kategori tidak konsisten, nilai di luar rentang, dan leakage.
- Menyusun data-quality report yang memisahkan bukti, dugaan sebab, risiko, dan tindakan.
- Menyusun problem-framing canvas setelah memahami struktur dan kualitas data.
- Menghasilkan EDA notebook, data-quality report, dan framing canvas satu halaman.

## C. Memuat Data dan Kamus Data

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt


pd.set_option("display.max_columns", 30)
df = pd.read_csv(DATA_DIR + "/student_learning_messy.csv")
dictionary = pd.read_csv(DATA_DIR + "/data_dictionary.csv")
print("Shape:", df.shape)
df.head()
```

*Selalu baca kamus data bersama dataset.*

**Pertanyaan 1.**
1) Berapa baris dan kolom data tersebut ?
2) Kolom apa saja yang legal ?

## D. Missing dan Duplikasi

```
audit_missing = pd.DataFrame({
    "missing_count": df.isna().sum(),
    "missing_pct": (df.isna().mean() * 100).round(1),
}).sort_values("missing_count", ascending=False)
audit_missing

print("Duplikat seluruh baris:", df.duplicated().sum())
print("Duplikat student_id:", df["student_id"].duplicated().sum())
df[df.duplicated(keep=False)].sort_values("student_id").head(10)
```

*Pemeriksaan missing dan duplikasi.*

**Pertanyaan 2**
1) Berapa banyak missing data missing?Tunjukkan
2) Berapa banyak duplikat data ? Tunjukkan

## E. Kategori Tidak Konsisten

```
for col in ["internet_access", "study_group", "program_track"]:
    print("\n", col)
    print(df[col].value_counts(dropna=False))
```

*value_counts membantu melihat ejaan, spasi, dan kategori langka.*

**Pertanyaan 3**
1) Buat tabel pemetaan kategori.
2) Ada berapa kategori seharusnya untuk setiap atribut ?

## F. Aturan Validitas

| Kolom | Aturan sementara | Tindakan bila melanggar |
|---|---|---|
| study_hours_per_week | 0–30 jam/minggu | Verifikasi satuan/input; tandai, jangan otomatis clamp. |
| attendance_pct | 0–100% | Nilai di luar rentang invalid. |
| prior_score | 0–100 | Periksa skala dan sumber. |
| practice_sessions | bilangan bulat ≥0 | Nilai negatif invalid; nilai sangat besar perlu verifikasi. |
| sleep_hours | 0–24 jam/hari | Periksa definisi rata-rata dan unit. |
| commute_minutes | ≥0 | Nilai negatif invalid; ekstrem bisa valid. |

```
rules = {
    "study_hours_per_week": (0, 30),
    "attendance_pct": (0, 100),
    "prior_score": (0, 100),
    "practice_sessions": (0, 20),
    "sleep_hours": (3, 12),
    "commute_minutes": (0, 180),
    "final_score": (0, 100),
}
issues=[]
for col,(lo,hi) in rules.items():
    mask = df[col].notna() & ~df[col].between(lo,hi)

issues.append({"column":col,"outside_range":int(mask.sum()),"examples":df.loc[m
ask,col].head(5).tolist()})
pd.DataFrame(issues)
```

*Contoh pemeriksaan rule-based.*

**Pertanyaan 4**
1) Identifikasi data **invalid** dan **outlier**.
2) Apakah ada yang perlu diverifikasi ?

## G. Visualisasi Audit

```
fig, axes = plt.subplots(1, 2, figsize=(11, 4))
axes[0].hist(df["attendance_pct"].dropna(), bins=20, edgecolor="white")
axes[0].set(title="Attendance termasuk nilai tidak valid", xlabel="Persen")
axes[1].boxplot(df["commute_minutes"].dropna(), vert=False)
axes[1].set(title="Outlier commute_minutes", xlabel="Menit")
plt.show()
```

**Pertanyaan 5**
1) Tulis satu interpretasi dan satu penjelasan alternatif untuk setiap grafik

## H. Audit Waktu dan Leakage

Target needs_support ditujukan sebagai sinyal sebelum ujian akhir. final_score belum tersedia pada waktu tersebut dan justru menentukan needs_support. Karena itu final_score merupakan target leakage. student_id adalah identifier, bukan fitur. Tuliskan “prediction time” pada canvas agar keputusan fitur dapat diperiksa.

```
candidate_features = [c for c in df.columns if c != "needs_support"]

availability = pd.DataFrame({

    "feature": candidate_features,

    "available_before_prediction": [False if c == "final_score" else True for c
in candidate_features],

    "reason": ["Nilai akhir belum tersedia dan langsung membentuk target." if c
== "final_score" else "Perlu verifikasi proses pengumpulan." for c in
candidate_features],
```

```
})

availability
```

## I. Problem-Framing Canvas

| Elemen | Jawaban yang harus ditulis |
|---|---|
| Keputusan | Tindakan yang dibantu model, bukan hanya output model. |
| Pengguna | Siapa yang melihat prediksi dan siapa yang terdampak. |
| Unit analisis | Makna satu baris dan periode waktunya. |
| Target | Definisi operasional dan kapan diketahui. |
| Prediction time | Waktu model dijalankan. |
| Allowed features | Fitur yang legal dan tersedia saat prediction time. |
| Baseline | Pembanding sederhana yang jujur. |
| Metrik | Metrik utama dan alasan biaya kesalahan. |
| Risiko/batas | Misuse, subgroup, privasi, dan kebutuhan human review. |

## J. Format Data-Quality Report

Susun Data Quality Report yang memuat: (a) minimal 5 temuan, (b) bukti kode/tabel/grafik,(c) jenis dan dugaan penyebab (d) risiko bila masalah diabaikan, dan (e) pertanyaan yang harus diajukan kepada pemilik data.

| ID | Bukti | Jenis isu | Dugaan sebab | Risiko | Tindakan/keputusan |
|---|---|---|---|---|---|
| | | | | | |