

Capaian Praktikum

Setelah menyelesaikan notebook ini, mahasiswa mampu:

1. Membaca struktur dataset nyata dan membedakan fitur dengan target.
2. Mengukur variasi fitur, relevansi linear terhadap target, dan redundansi antarf fitur.
3. Menerapkan feature selection berbasis filter secara transparan dan melakukan sensitivity analysis terhadap threshold.
4. Melakukan standardisasi dan PCA sebagai feature extraction tanpa melatih model prediktif.
5. Membaca explained variance ratio, cumulative explained variance, dan loading PCA.
6. Mengukur information loss dengan reconstruction MSE serta membandingkan feature selection dan PCA dari sisi kompresi dan interpretabilitas.
7. Menulis representation-risk note singkat.

Dataset yang digunakan

Praktikum menggunakan Diabetes dataset yang tersedia langsung melalui scikit-learn

Catatan etika data
Dataset digunakan untuk tujuan pembelajaran analitik. Korelasi dalam praktikum tidak boleh ditafsirkan sebagai hubungan sebab-akibat atau dasar keputusan klinis. Fitur demografis dengan korelasi global rendah juga tidak otomatis aman untuk dihapus bila dibutuhkan untuk audit subgroup.

0. Persiapan

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.datasets import load_diabetes
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

raw = load_diabetes(scaled=False, as_frame=True)
df = raw.frame.copy()
features = raw.feature_names
print(df.shape)
display(df.head())
```

1. Bagian A - Memahami Dataset

Pertanyaan 1. Berapa jumlah observasi, jumlah fitur input, dan jumlah target pada dataset? Tuliskan dalam bentuk n = ... dan p = ...

Pertanyaan 2. Apa perbedaan peran kolom target dengan sepuluh kolom lainnya pada praktikum ini?

```
print(df.info())
print('Missing value per kolom:')
print(df.isna().sum())
display(df.describe().T)
```

Pertanyaan 3. Apakah terdapat missing value? Jika tidak ada, apa implikasinya untuk langkah praktikum berikutnya?

2. Bagian B - Variance: Apakah Fitur Membawa Variasi?

```
X = df[features]
y = df['target']
variance_pop = X.var(ddof=0).sort_values(ascending=False)
display(variance_pop.to_frame('population_variance'))
```

Pertanyaan 4. Fitur apa yang memiliki variance populasi terbesar dan terkecil? Apakah variance terbesar otomatis berarti fitur paling relevan terhadap target? Jelaskan.

Pertanyaan 5. Adakah fitur dengan variance = 0 pada dataset nyata ini? Jika tidak ada, apa artinya terhadap variance-threshold = 0?

Checkpoint konsep
Variance mengukur penyebaran satu fitur, bukan hubungan fitur dengan target. Karena skala fitur berbeda, besar variance mentah tidak boleh langsung dipakai untuk menyimpulkan relevansi.

3. Bagian C - Relevansi Linear dengan Pearson Correlation

```
train_drop = train_imp.dropna(subset=["study_hours_week"]).copy()
val_drop = val_imp.dropna(subset=["study_hours_week"]).copy()

print("Train sebelum/sesudah drop:", len(train_imp), len(train_drop))
print(
    "Positive sebelum/sesudah:",
    int(train_imp["needs_support"].sum()),
    int(train_drop["needs_support"].sum())
)
```

4. Bagian C - Relevansi Linear dengan Pearson Correlation

```
corr_target = df.corr(numeric_only=True)['target'].drop('target')
corr_target = corr_target.sort_values(key=lambda s: s.abs(), ascending=False)
display(corr_target.to_frame('pearson_r'))
```

Pertanyaan 6. Sebutkan tiga fitur dengan |r| terbesar terhadap target. Untuk masing-masing, tuliskan tanda korelasi (+/-) dan artinya secara deskriptif.

Pertanyaan 7. Fitur sex mempunyai korelasi global yang rendah terhadap target. Apakah itu cukup untuk menyimpulkan fitur tersebut tidak berguna? Jelaskan tanpa membuat klaim kausal.

```
for threshold in [0.20, 0.30, 0.40, 0.50]:
    selected = corr_target[corr_target.abs() >= threshold].index.tolist()
    print(f'threshold={threshold:.2f} -> {len(selected)} fitur: {selected}')
```

Pertanyaan 8. Pada threshold |r| >= 0.40, fitur apa saja yang terpilih? Berapa persen reduksi dimensi dari 10 fitur awal?

Pertanyaan 9. Bandingkan hasil threshold 0.20, 0.30, 0.40, dan 0.50. Fitur mana yang stabil muncul dan fitur mana yang sensitif terhadap threshold?

5. Bagian D - Redundansi Antar Fitur

```
feature_corr = X.corr()
pairs = []
for i, a in enumerate(features):
    for j in range(i+1, len(features)):
        b = features[j]
        pairs.append((a, b, feature_corr.loc[a,b]))

pairs_df = pd.DataFrame(pairs, columns=['feature_1','feature_2','r'])
pairs_df['abs_r'] = pairs_df['r'].abs()
display(pairs_df.sort_values('abs_r', ascending=False).head(10))
```

Pertanyaan 10. Pasangan fitur mana yang mempunyai |r| tertinggi? Apakah korelasinya cukup tinggi untuk dianggap redundan jika aturan contoh |r| >= 0.85?
Pertanyaan 11. Untuk pasangan s1 dan s2, bandingkan korelasi masing-masing terhadap target. Jika harus mempertahankan satu fitur saja, mana yang Anda pilih berdasarkan bukti ini? Jelaskan keterbatasan keputusan tersebut.
Pertanyaan 12 Mengapa korelasi tinggi antara fitur disebut redundansi, sedangkan korelasi tinggi fitur-target disebut relevansi?

6. Bagian E - Standardisasi dan PCA sebagai Feature Extraction

```
scaler = StandardScaler()
X_std = scaler.fit_transform(X)
X_std = pd.DataFrame(X_std, columns=features, index=X.index)
display(X_std.head())
display(X_std.agg(['mean','std']).T)
```

Pertanyaan 13. Mengapa standardisasi diperlukan sebelum PCA pada dataset ini? Gunakan contoh perbedaan skala dua fitur dari statistik deskriptif untuk mendukung jawaban.

```
pca = PCA()
Z = pca.fit_transform(X_std)
ev = pca.explained_variance_
evr = pca.explained_variance_ratio_
cum_evr = np.cumsum(evr)

pca_summary = pd.DataFrame({
    'PC': [f'PC{i+1}' for i in range(len(evr))],
    'eigenvalue': ev,
    'EVR': evr,
    'cumulative_EVR': cum_evr
})
display(pca_summary)
```

Pertanyaan 14. Berapa jumlah PC minimum untuk mencapai cumulative explained variance 80%, 90%, dan 95%?

Pertanyaan 15. Jelaskan arti cumulative EVR sekitar 90%. Mengapa angka tersebut bukan accuracy dan bukan persentase informasi target?

```
loadings = pd.DataFrame(
    pca.components_.T,
    index=features,
    columns=[f'PC{i+1}' for i in range(len(features))]
)
for pc in ['PC1','PC2']:
    print()
    print(pc)
```

```
    display(loadings[pc].sort_values(key=lambda s: s.abs(),
ascending=False).head(5).to_frame('loading'))
```

Pertanyaan 16. Sebutkan tiga fitur dengan absolute loading terbesar pada PC1 dan PC2. Apa yang dapat dan tidak dapat Anda simpulkan dari loading tersebut?

7. Bagian F - Projection, Reconstruction, dan Information Loss

```
scores = pd.DataFrame(
    Z[:, :3],
    columns=['PC1_score','PC2_score','PC3_score'],
    index=X.index
)
display(pd.concat([X_std.head(5), scores.head(5)], axis=1))
```

Pertanyaan 17. Untuk observasi pertama, apakah PC1_score dapat dibaca sebagai BMI, tekanan darah, atau kolesterol? Jelaskan apa arti score PCA.

```
rows = []
for k in [5,7,8,10]:
    p = PCA(n_components=k)
    Zk = p.fit_transform(X_std)
    X_rec = p.inverse_transform(Zk)
    mse = np.mean((X_std.to_numpy() - X_rec)**2)
    rows.append({
        'k': k,
        'cumulative_EVR': p.explained_variance_ratio_.sum(),
        'reconstruction_MSE': mse
    })
reconstruction_table = pd.DataFrame(rows)
display(reconstruction_table)
```

Pertanyaan 18. Bagaimana reconstruction MSE berubah ketika k meningkat dari 5 ke 7, 8, lalu 10? Jelaskan hubungan antara jumlah PC, explained variance, dan information loss. Pada k=10, mengapa MSE mendekati nol dan apakah ini berarti PCA selalu lossy?

8. Bagian G - Membandingkan Feature Selection dan PCA

```
selected_040 = corr_target[corr_target.abs() >= 0.40].index.tolist()
k90 = int(np.argmax(cum_evr >= 0.90) + 1)
print('Feature selection |r|>=0.40:', selected_040, '->', len(selected_040),
'fitur')
print('PCA threshold 90% ->', k90, 'PC dari', len(features), 'fitur')
```

Pertanyaan 19. Bandingkan feature selection threshold |r|>=0.40 dengan PCA threshold 90% dari sisi jumlah dimensi, nama fitur, interpretabilitas, dan jenis information loss. Jika hasil harus dijelaskan kepada pengguna nonteknis, metode mana yang lebih mudah diaudit?

Pertanyaan 20. Tuliskan representation-risk note 3-5 kalimat dan keputusan akhir Anda: pilih feature selection, PCA, keduanya secara berurutan, atau tidak melakukan reduksi. Berikan minimal tiga alasan berbasis hasil eksperimen dan jelaskan mengapa keputusan tidak boleh hanya berdasarkan satu threshold.

Referensi

Scikit-learn: Diabetes dataset (load_diabetes) dan implementasi StandardScaler/PCA.

Géron, A. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 3rd ed.

James, G. et al. An Introduction to Statistical Learning with Applications in Python.

Molnar, C. Interpretable Machine Learning.