Bab 2. Fondasi Matematis untuk ML

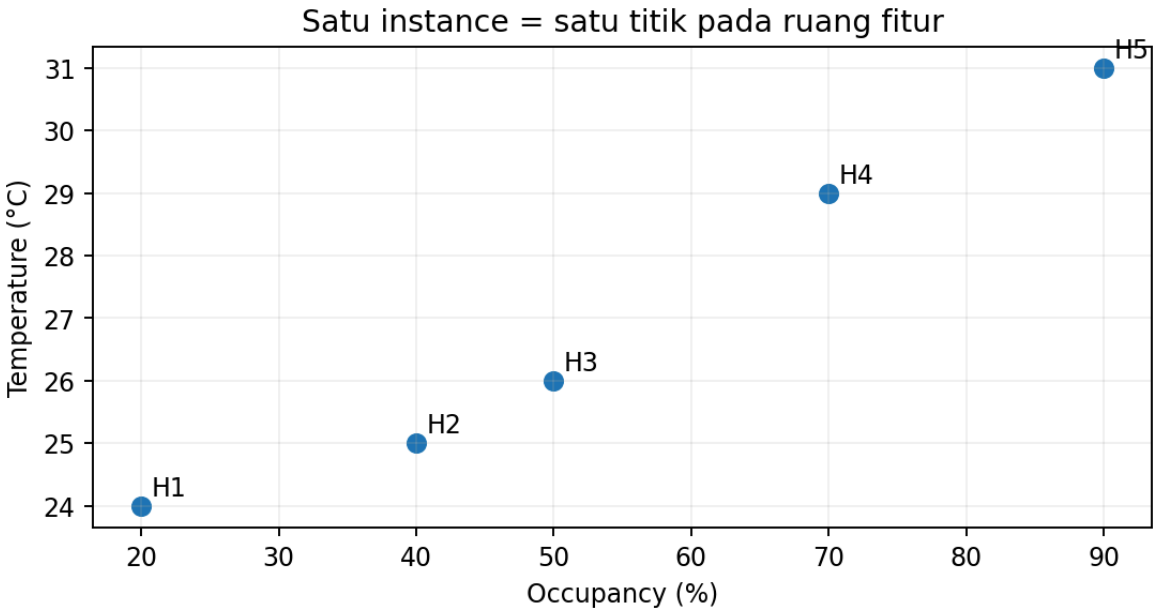
Capaian
Mahasiswa mampu menjelaskan dan menggunakan vektor, matriks, jarak/similarity, distribusi, fungsi objektif, loss, dan optimisasi yang relevan bagi pipeline machine learning.

2.1 Mengapa Data Harus Direpresentasikan sebagai Angka?

Penjelasan teori. Model tidak bekerja langsung dengan konsep abstrak seperti "ruang ramai" atau "udara buruk". Informasi harus direpresentasikan sebagai feature yang dapat diolah. Skalar adalah satu nilai. Vektor adalah sekumpulan nilai yang menggambarkan satu instance. Matriks menggabungkan banyak instance sehingga satu baris mewakili observasi dan satu kolom mewakili feature. Jika ada n instance dan p feature, maka X memiliki shape (n,p).

Contoh/analogi. Analogi koordinat peta: satu titik membutuhkan beberapa koordinat. Dengan dua feature, satu instance adalah titik pada bidang; dengan puluhan feature, kita berada pada ruang berdimensi tinggi yang tidak dapat divisualisasikan langsung tetapi matematika vektor tetap bekerja.

Perhitungan/visualisasi. Contoh lima hari smart-lab: x_H3=[occupancy=50, temperature=26]. Lima hari menjadi matriks 5x2. Target energy membentuk vektor y terpisah.



Gambar 2.1. Setiap instance dapat dipandang sebagai titik pada ruang fitur.

Hari	Occupancy (%)	Temperature (C)	Energy aktual (kWh)
H1	20	24	18
H2	40	25	25
H3	50	26	29
H4	70	29	38
H5	90	31	47

Praktik mini - Dari tabel ke X dan y

1. Tulis x_H3 sebagai vektor.

2. Susun X berukuran 5x2.

3. Tulis y sebagai vektor target.

4. Jelaskan apa arti X.shape=(5,2) tanpa memakai istilah Python.

2.2 Dot Product: Mekanisme Dasar Banyak Model

Penjelasan teori. Dot product mengalikan pasangan elemen dua vektor lalu menjumlahkannya. Dalam model linear, feature dikalikan bobotnya lalu dijumlahkan bersama intercept. Karena itu dot product bukan sekadar operasi aljabar; ia adalah mekanisme menggabungkan kontribusi feature menjadi score atau prediction.

Contoh/analogi. Analogi nilai akhir: nilai tugas, UTS, dan UAS dikalikan bobot 20%, 30%, 50%, lalu dijumlahkan. Bobot menentukan seberapa kuat setiap komponen memengaruhi hasil.

Perhitungan/visualisasi. Gunakan model y_hat = 5 + 0.4*occupancy + 0.2*temperature. Untuk H3, y_hat=5+0.4(50)+0.2(26)=30.2 kWh. Error terhadap target 29 adalah -1.2 kWh bila residual=y-y_hat.

$$\mathbf{x} \cdot \mathbf{w} = \Sigma_j \, x_j \, w_j$$

```
x = np.array([50.0, 26.0])
w = np.array([0.4, 0.2])
y_hat = 5 + x @ w
print(y_hat)  # 30.2
```

Praktik mini - Bobot sebagai pengaruh

1. Pertahankan x_H3.

2. Ubah bobot occupancy 0.4 menjadi 0.2 lalu 0.6.

3. Catat prediksi untuk tiga bobot.

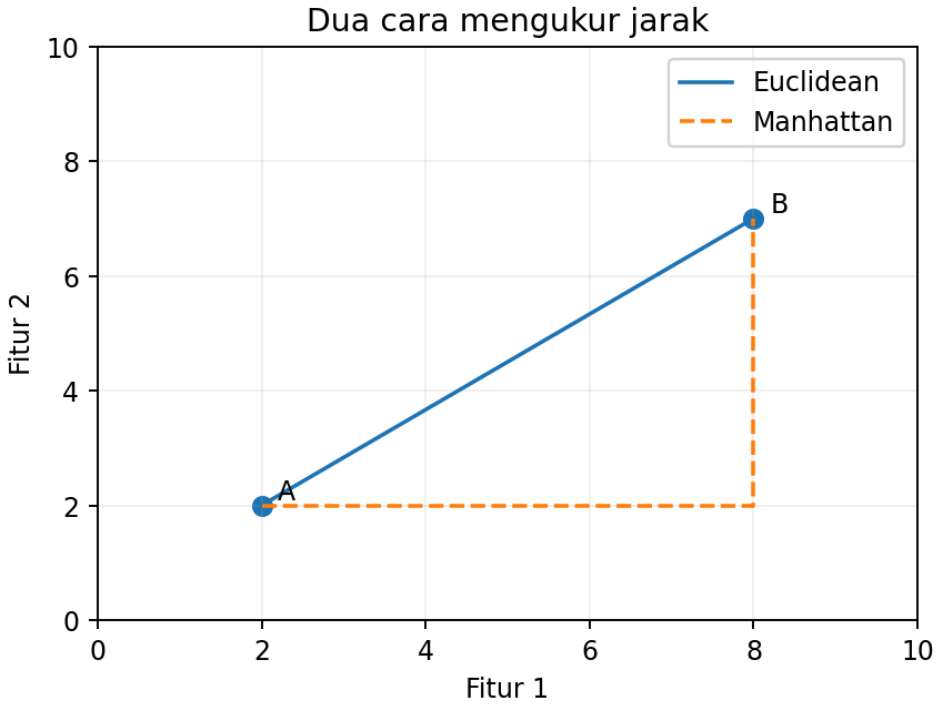
4. Jelaskan mengapa perubahan parameter menggeser prediksi.

2.3 Jarak dan Similarity: "Dekat" Bergantung pada Definisi

Penjelasan teori. Algoritma seperti k-nearest neighbors dan clustering memerlukan definisi kedekatan. Euclidean distance mengukur panjang garis lurus; Manhattan distance menjumlahkan selisih absolut tiap dimensi. Tidak ada satu ukuran jarak yang selalu benar. Pilihan jarak adalah asumsi tentang bentuk kemiripan yang relevan.

C**ontoh/analogi.** Analogi kota: Euclidean adalah jarak burung terbang; Manhattan adalah perjalanan mengikuti blok jalan. Keduanya mengukur dua titik yang sama tetapi menghasilkan angka berbeda karena geometri yang diasumsikan berbeda.

Perhitungan/visualisasi. Masalah berikutnya adalah skala. Selisih occupancy 50 poin dapat menenggelamkan selisih temperatur 6 C. Standardization membuat feature relatif sebanding dengan mengukur berapa standard deviation sebuah nilai dari mean training.



Gambar 2.2. Euclidean dan Manhattan mengasumsikan geometri yang berbeda.

$$d_E(x,z) = \text{sqrt}(\Sigma_j\ (x_j - z_j)^2) \qquad d_M(x,z) = \Sigma_j\ |x_j - z_j|$$

Praktik mini - Jarak sebelum dan sesudah scaling

1. Hitung Euclidean H2=[40,25] dan H5=[90,31].

2. Hitung mean dan standard deviation dua feature dari lima hari.

3. Standardisasi H2 dan H5, lalu hitung jarak lagi.

4. Jelaskan apakah scaling hanya mengubah satuan atau juga geometri algoritma.

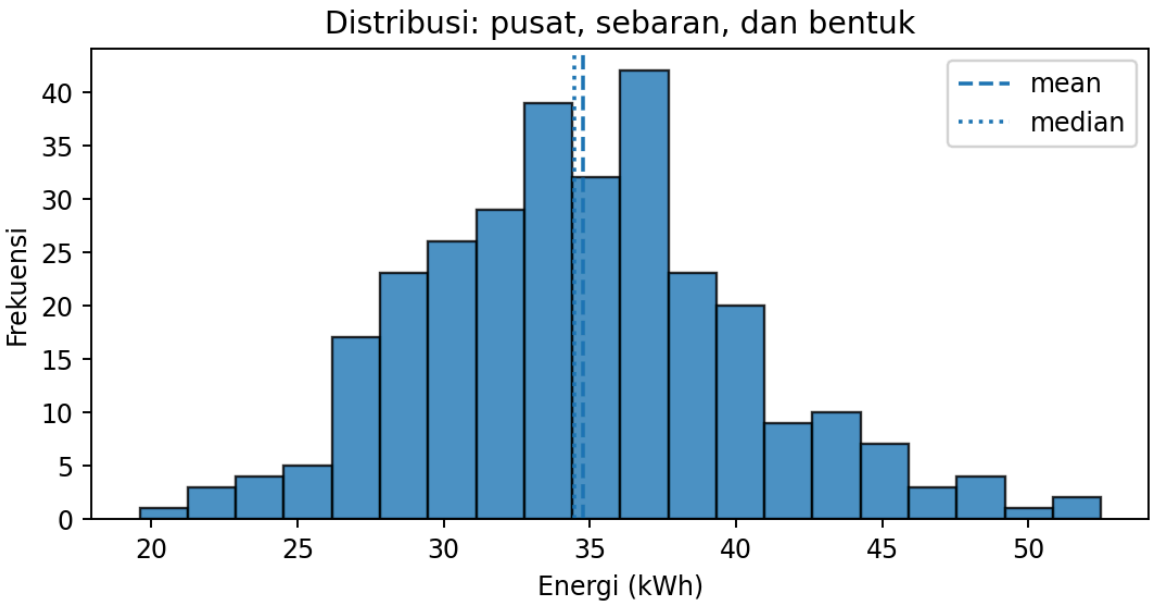
2.4 Mean, Median, Variance, Standard Deviation, dan Distribusi

Penjelasan teori. Mean merangkum pusat dengan menggunakan semua nilai; median menggunakan posisi tengah dan lebih robust terhadap nilai ekstrem. Variance mengukur rata-rata kuadrat penyimpangan dari mean, sedangkan standard deviation mengembalikan ukuran sebaran ke satuan asli. Distribusi memberi konteks terhadap ringkasan tersebut: dua dataset dapat mempunyai mean sama tetapi bentuk dan risiko yang berbeda.

Contoh/analogi. Analogi dua kelas dengan rata-rata 75. Kelas A semua nilai 73-77; kelas B separuh 50 dan separuh 100. Mean sama, tetapi ketidakpastian saat menebak nilai seorang mahasiswa sangat berbeda.

Perhitungan/visualisasi. Untuk energy=[18,25,29,38,47], mean=31.4 dan median=29. Nilai ekstrem baru 100 akan menarik mean jauh lebih besar, sedangkan median berubah lebih sedikit.

$$\text{mean} = (1/n)\ \Sigma_i\ x_i \qquad s^2 = [1/(n-1)]\ \Sigma_i\ (x_i - \text{mean})^2 \qquad s = \text{sqrt}(s^2)$$



Gambar 2.3. Distribusi harus dibaca bersama mean/median dan ukuran sebaran.

Praktik mini - Ringkasan dan nilai ekstrem

1. Hitung mean dan median energy lima hari.

2. Ganti 47 menjadi 100.

3. Hitung ulang mean dan median.

4. Jelaskan ringkasan mana yang lebih robust dan kapan robustness dibutuhkan.

2.5 Probabilitas: Bahasa untuk Ketidakpastian

Penjelasan teori. Probabilitas adalah cara kuantitatif menyatakan ketidakpastian. Dalam ML, model klasifikasi sering menghasilkan probability score; sampling dan noise juga dipahami secara probabilistik. Probabilitas bukan kepastian individual. Nilai 0.8 berarti dalam kerangka model/data tertentu event lebih mungkin daripada 0.2, tetapi kualitas angka bergantung kalibrasi, representativeness, dan asumsi.

Contoh/analogi. Analogi prakiraan hujan 70% bukan pernyataan bahwa 70% kota pasti basah. Ia menyatakan tingkat keyakinan/frekuensi dalam kondisi yang sebanding.

Perhitungan/visualisasi. Probabilitas empiris dapat dihitung sebagai proporsi observasi yang memenuhi kondisi, misalnya proporsi energy >40 pada sampel. Nilai ini dapat berubah jika sampel berubah.

Praktik mini - Probabilitas empiris dan seed

1. Buat 300 nilai simulasi normal mean 35 sd 6.

2. Hitung proporsi >40.

3. Ubah threshold menjadi 45.

4. Ubah seed dan jelaskan perubahan hasil.

Interpretasi yang diharapkan: Mahasiswa membedakan probabilitas empiris, random variation, dan reproducibility.

2.6 Error, Loss, dan Objective Function

Penjelasan teori. Prediction error adalah selisih antara nilai aktual dan prediksi. Loss mengubah error menjadi angka yang dapat dibandingkan dan dioptimalkan. MAE menggunakan nilai absolut; MSE mengkuadratkan error sehingga kesalahan besar mendapat penalti lebih tinggi. Objective function adalah

besaran yang benar-benar diminimalkan saat training. Objective bisa sama dengan rata-rata loss, atau loss ditambah regularization.

Contoh/analogi. Analogi panah ke target: error menunjukkan seberapa jauh tiap panah meleset. Loss memberi skor pada tiap kesalahan. Objective menggabungkan skor semua panah menjadi satu nilai yang dijadikan target perbaikan latihan.

Perhitungan/visualisasi. Karena pilihan loss menentukan apa yang dianggap "buruk", pemilihan objective adalah keputusan desain, bukan formalitas matematika.

$$MSE = (1/n)\ \Sigma_i\ (y_i - y_hat_i)^2$$

Hari	y	y_hat	error	error^2
H1	18.0	17.8	0.2	0.04
H2	25.0	26.0	-1.0	1.00
H3	29.0	30.2	-1.2	1.44
H4	38.0	38.8	-0.8	0.64
H5	47.0	47.2	-0.2	0.04

Praktik mini - Satu error besar

1. Hitung MAE dan MSE dari tabel.

2. Ganti prediksi H5 menjadi 70.

3. Hitung ulang MAE dan MSE.

4. Jelaskan mengapa MSE berubah lebih tajam.

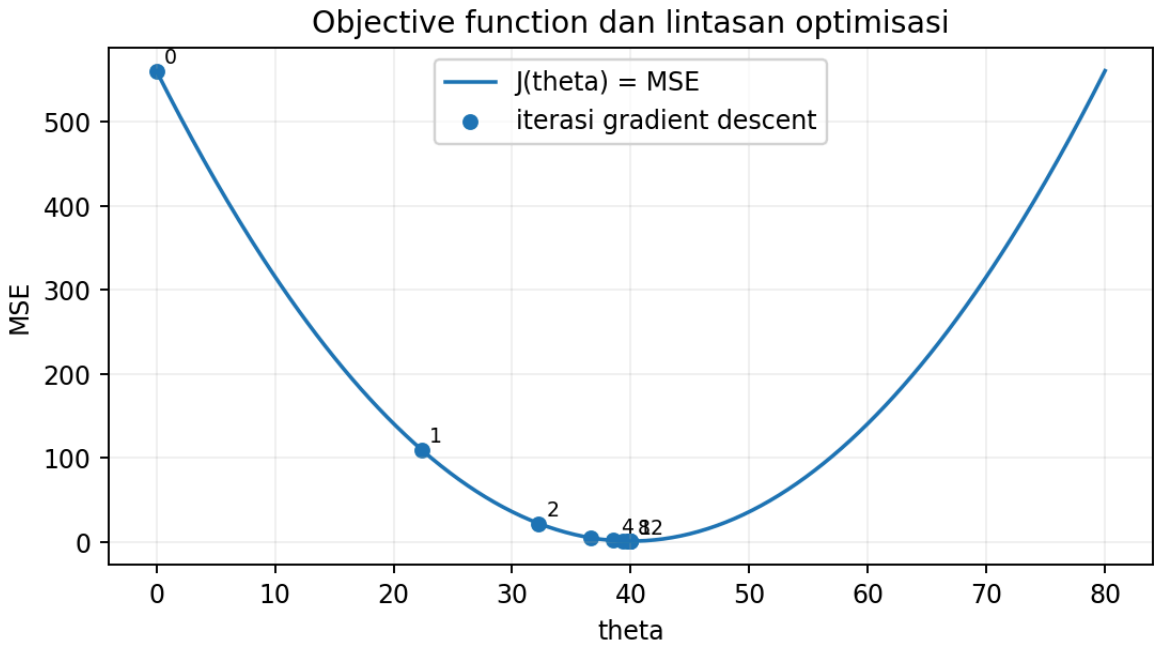
2.7 Optimisasi: Bagaimana Training Mengubah Parameter

Penjelasan teori. Setelah objective didefinisikan, training memerlukan prosedur untuk mencari parameter yang membuat objective kecil. Gradient adalah kemiringan lokal objective terhadap parameter: tandanya memberi arah, besarannya memberi sensitivitas. Gradient descent bergerak berlawanan arah gradient. Proses ini iteratif: predict -> hitung loss/objective -> hitung gradient -> update parameter -> ulangi.

Contoh/analogi. Analogi turun gunung dalam kabut: kita tidak melihat seluruh lembah, tetapi dapat merasakan arah kemiringan lokal. Learning rate seperti panjang langkah. Terlalu kecil membuat perjalanan lambat; terlalu besar dapat melompati lembah dan tidak stabil.

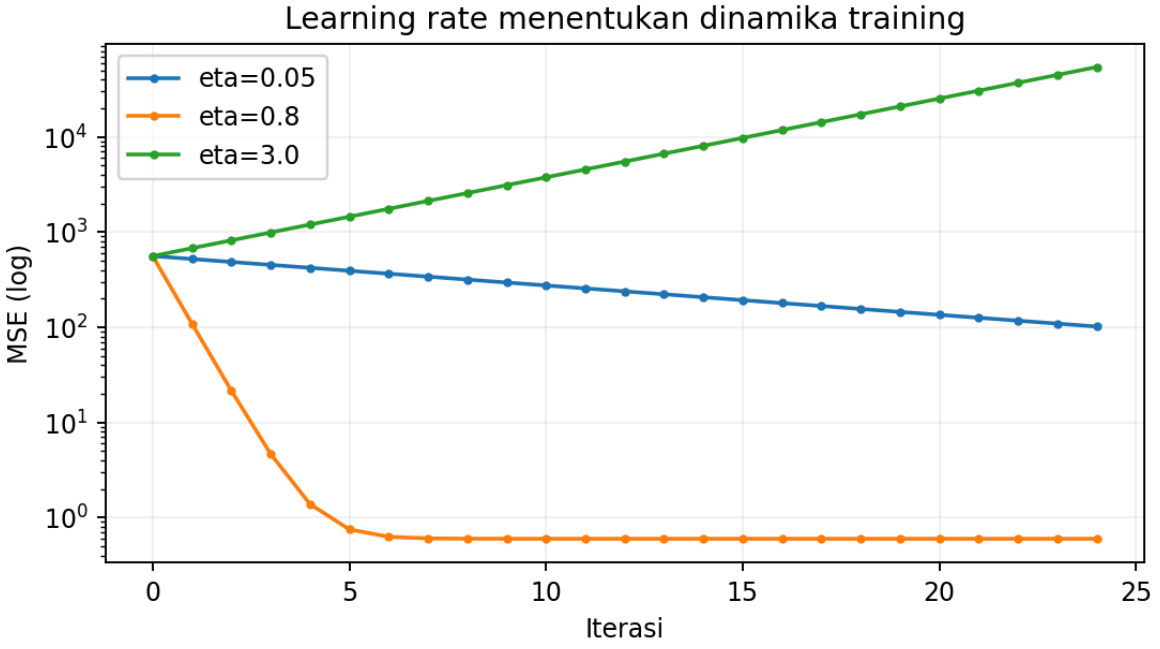
Perhitungan/visualisasi. Gunakan model satu parameter y_hat=10+theta*x, dengan x=occupancy/100. Objective J(theta)=MSE. Dengan theta awal 0, tiap iterasi mengurangi MSE menuju minimum sekitar theta 40 pada contoh ini.

$$theta_(t+1) = theta_t - eta * dJ/dtheta$$



Gambar 2.4. Objective function membentuk landscape; training bergerak dari parameter awal menuju minimum.

Iterasi	theta	MSE
0	0.000	560.600
1	22.400	109.016
2	32.256	21.589
3	36.593	4.664
4	38.501	1.387
6	39.710	0.629
8	39.944	0.601
12	39.998	0.600



Gambar 2.5. Learning rate mengubah kecepatan dan stabilitas optimisasi.

Praktik mini - Learning-rate experiment

1. Jalankan gradient descent theta awal 0.

2. Bandingkan eta=0.05, 0.8, dan 3.0.

3. Plot MSE per iterasi.

4. Labeli run sebagai lambat, konvergen, atau divergen dan jelaskan mekanismenya.

Pertanyaan diskusi: Jika objective non-convex memiliki beberapa lembah, apa konsekuensi parameter awal?

2.8 Aktivitas Teori

Latihan hitung berpasangan

Diberikan x = [4, 80, 65] dan z = [7, 74, 73]. Hitung selisih per komponen, jarak Manhattan, dan jarak Euclidean. Setelah itu diskusikan: apakah perhitungan adil jika fitur pertama jam, sedangkan fitur kedua dan ketiga berskala 0–100?

Peer instruction

Pilih benar/salah dan berikan alasan: (1) random seed membuat data menjadi benar; (2) shape (100, 5) berarti 100 fitur dan 5 instance; (3) loss yang lebih kecil selalu berarti model lebih bermanfaat; (4) dot product menggabungkan fitur dan bobot.

2.9 Ringkasan

- Python menyediakan sintaks; NumPy menyediakan representasi dan operasi numerik yang efisien.
- Shape X = (n, p) berarti n instance dan p fitur.
- Dot product, jarak, mean, variance, dan loss merupakan fondasi yang akan muncul berulang.
- Skala fitur memengaruhi jarak dan banyak algoritma.
- Training adalah optimisasi parameter terhadap objective, bukan proses yang magis.

2.10 Cek Pemahaman

1. Apa perbedaan list Python dan array NumPy dari sudut pandang penggunaan?
2. Jelaskan arti X.shape = (320, 10).
3. Hitung dot product [1, 2, 3] dan [4, 0, −1].
4. Mengapa MSE sensitif terhadap kesalahan yang sangat besar?
5. Apa yang direproduksi oleh random seed dan apa yang tidak dijamin olehnya?