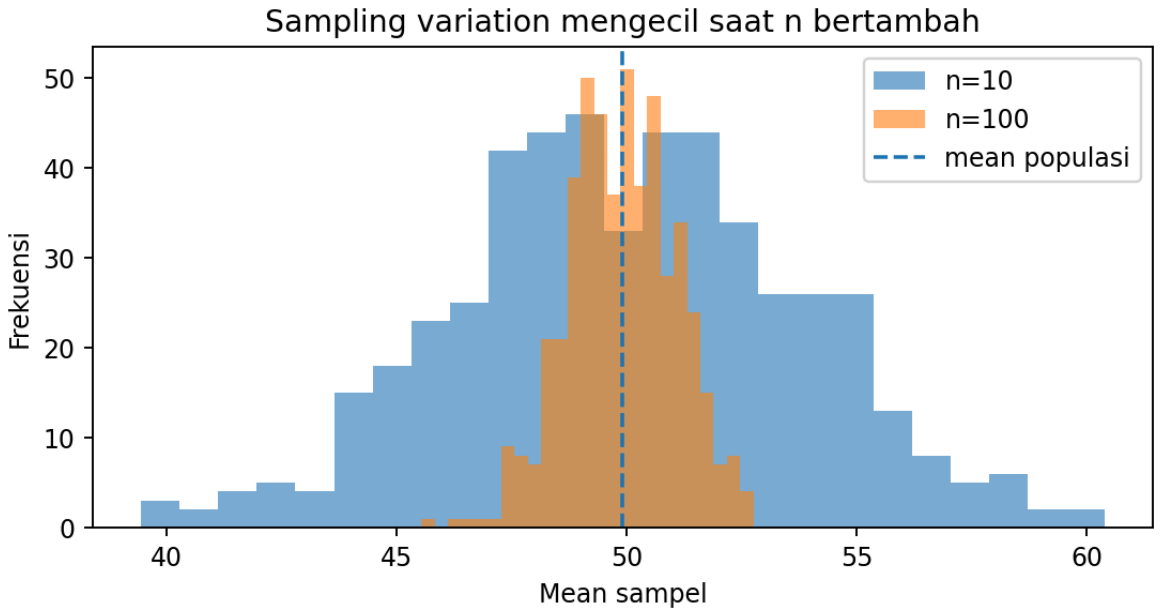



**Capaian**
Mahasiswa mampu menggunakan sampling, split, cross-validation, generalisasi, bias-variance, regularisasi, dan metrik untuk menafsirkan performa model; serta merancang eksperimen yang dapat direproduksi.

## 3.1 Population, Sample, Sampling Variation, dan Sampling Bias

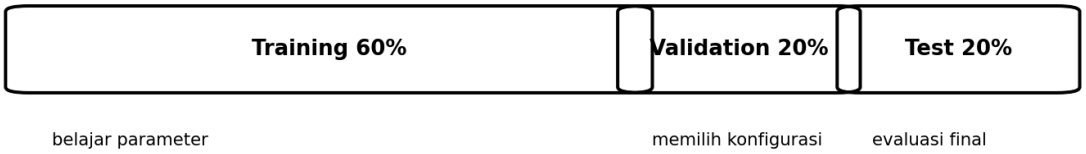
**Penjelasan teori.** Population adalah keseluruhan kasus yang menjadi sasaran kesimpulan; sample adalah bagian yang benar-benar diamati. Sampling variation muncul karena sampel acak berbeda akan menghasilkan statistik sedikit berbeda. Sampling bias muncul ketika mekanisme pengambilan sampel secara sistematis membuat sebagian kasus lebih mungkin masuk daripada yang lain. Menambah ukuran sampel mengurangi variasi acak, tetapi tidak memperbaiki bias mekanisme.
**Contoh/analogi.** Analogi mengambil satu sendok sup. Jika sup sudah diaduk merata, sendok lebih besar memberi estimasi rasa lebih stabil. Jika minyak selalu mengapung dan kita hanya mengambil dari permukaan, sepuluh sendok pun tetap bias.
**Perhitungan/visualisasi.** Dalam IoT, data hanya saat perangkat online dapat bias terhadap periode gangguan jaringan. Sampel sangat besar dari perangkat aktif tidak mewakili perangkat yang sering offline.




*Gambar 3.1. Sampel lebih besar memperkecil sampling variation, bukan otomatis sampling bias.*

## 3.2 Train, Validation, dan Test: Mengapa Satu Dataset Harus Memiliki Peran Berbeda

**Penjelasan teori.** Training set dipakai untuk belajar parameter. Validation set atau cross-validation dipakai untuk memilih model, hyperparameter, feature, threshold, dan preprocessing. Test set memberikan estimasi final generalization error setelah keputusan model selesai. Jika test dilihat berulang, informasi test masuk ke proses pengembangan dan test tidak lagi independen.
**Contoh/analogi.** Analogi belajar: training adalah latihan soal dengan pembahasan; validation adalah try-out untuk memilih strategi belajar; test adalah ujian akhir. Membaca kunci ujian akhir sambil menyesuaikan strategi membuat nilai ujian tidak lagi mengukur kemampuan pada soal baru.
**Perhitungan/visualisasi.** Untuk time series, pembagian acak dapat membawa data masa depan ke training. Split harus mengikuti struktur waktu bila tujuan deployment juga bergerak dari masa lalu ke masa depan.



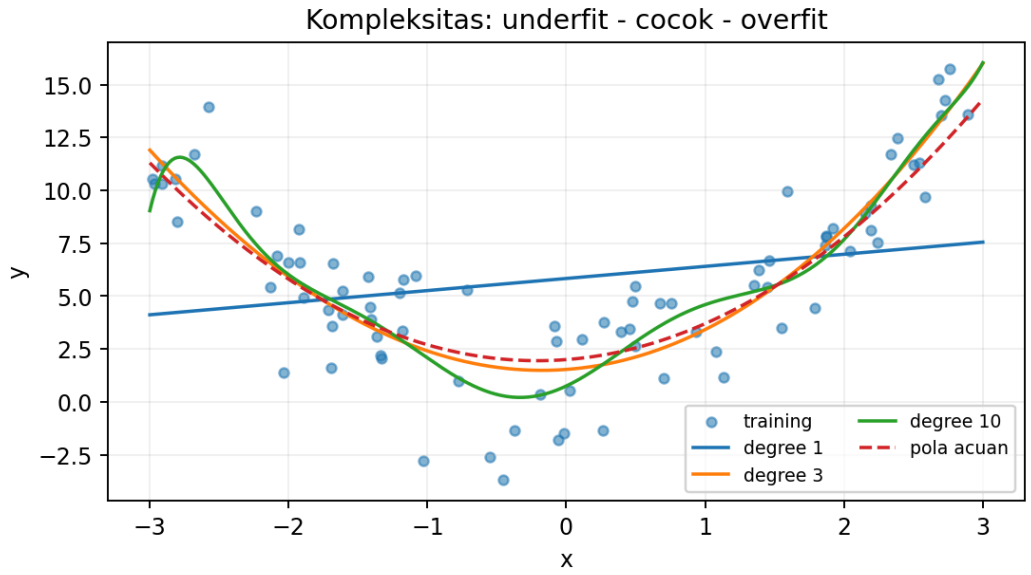

*Gambar 3.2. Training, validation, dan test mempunyai fungsi epistemik yang berbeda.*

## 3.3 Generalisasi, Underfitting, dan Overfitting

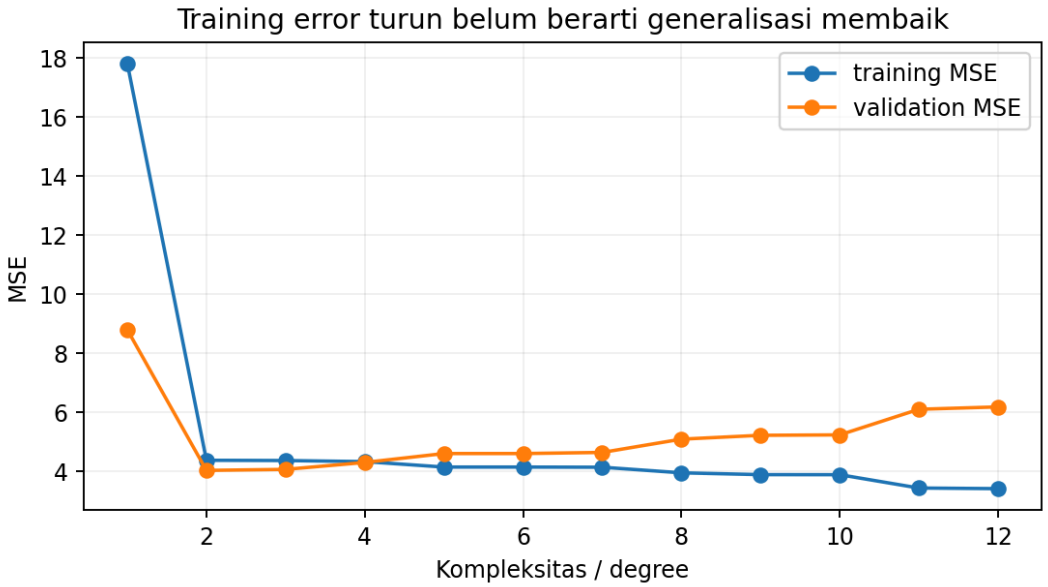
**Penjelasan teori.** Generalisasi adalah kemampuan model bekerja pada data baru dari target distribution yang relevan. Training performance penting tetapi tidak cukup. Underfitting terjadi ketika model terlalu sederhana atau feature tidak cukup sehingga error training dan validation sama-sama tinggi. Overfitting terjadi ketika model terlalu menyesuaikan kekhasan/noise training: training error sangat rendah tetapi validation/test error meningkat.

**Contoh/analogi.** Analogi menghafal versus memahami. Mahasiswa yang menghafal semua jawaban latihan bisa sempurna pada soal yang sama tetapi gagal saat angka/konteks berubah. Model yang terlalu fleksibel dapat melakukan hal serupa pada data training.

**Perhitungan/visualisasi.** Model complexity bukan selalu jumlah parameter saja; depth tree, degree polynomial, jumlah feature, atau kelemahan regularization dapat meningkatkan fleksibilitas.




*Gambar 3.3. Model terlalu sederhana gagal menangkap pola; model terlalu kompleks mengikuti noise.*



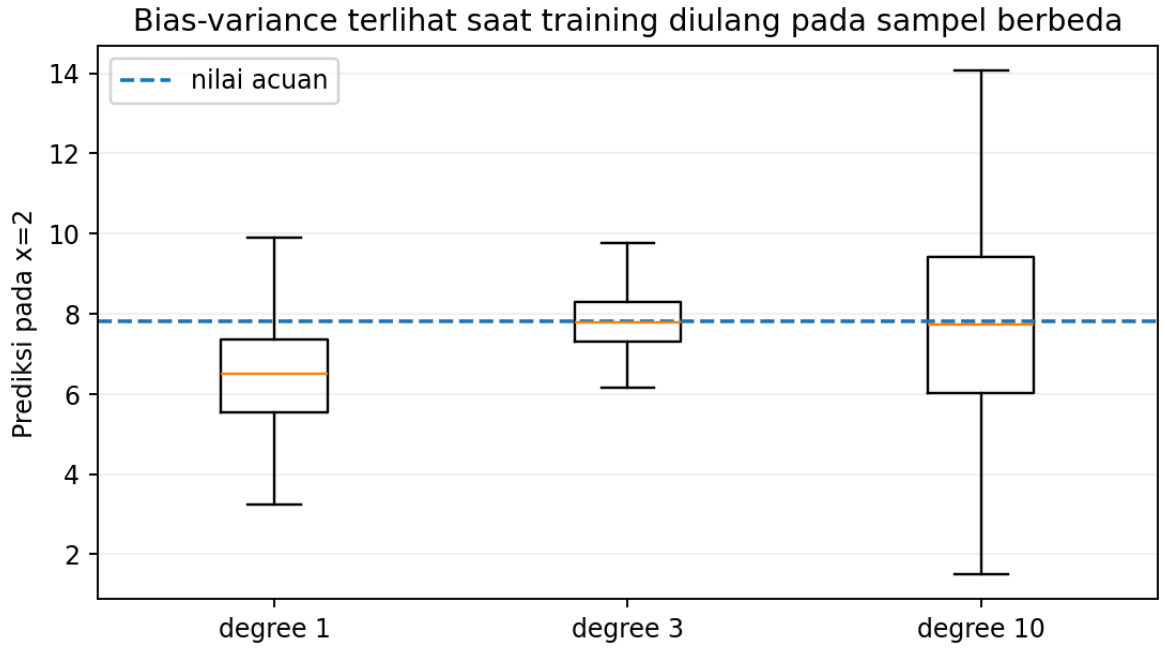

*Gambar 3.4. Training error terus turun, tetapi validation error dapat membentuk kurva U.*

## 3.4 Bias-Variance Trade-off

Penjelasan teori. Bias mengacu pada kesalahan sistematis karena model terlalu membatasi bentuk hubungan. Variance mengacu pada sensitivitas model terhadap perubahan training sample. Model sangat sederhana cenderung bias tinggi tetapi variance rendah; model sangat fleksibel cenderung bias rendah tetapi variance tinggi. Tujuan bukan meminimalkan salah satu secara terpisah, melainkan menemukan konfigurasi dengan generalization error yang baik.

**Contoh/analogi.** Analogi panahan: bias tinggi = semua panah rapat tetapi jauh dari pusat; variance tinggi = rata-rata mungkin dekat pusat tetapi panah tersebar lebar. Model yang baik membutuhkan keduanya cukup rendah.

**Perhitungan/visualisasi.** Bias/variance tidak dapat biasanya dihitung persis pada satu dataset real karena fungsi benar tidak diketahui; konsep dipakai untuk menafsirkan pola melalui repeated sampling/CV.




*Gambar 3.5. Model yang sama dilatih pada sampel berbeda menghasilkan variasi prediksi yang berbeda.*

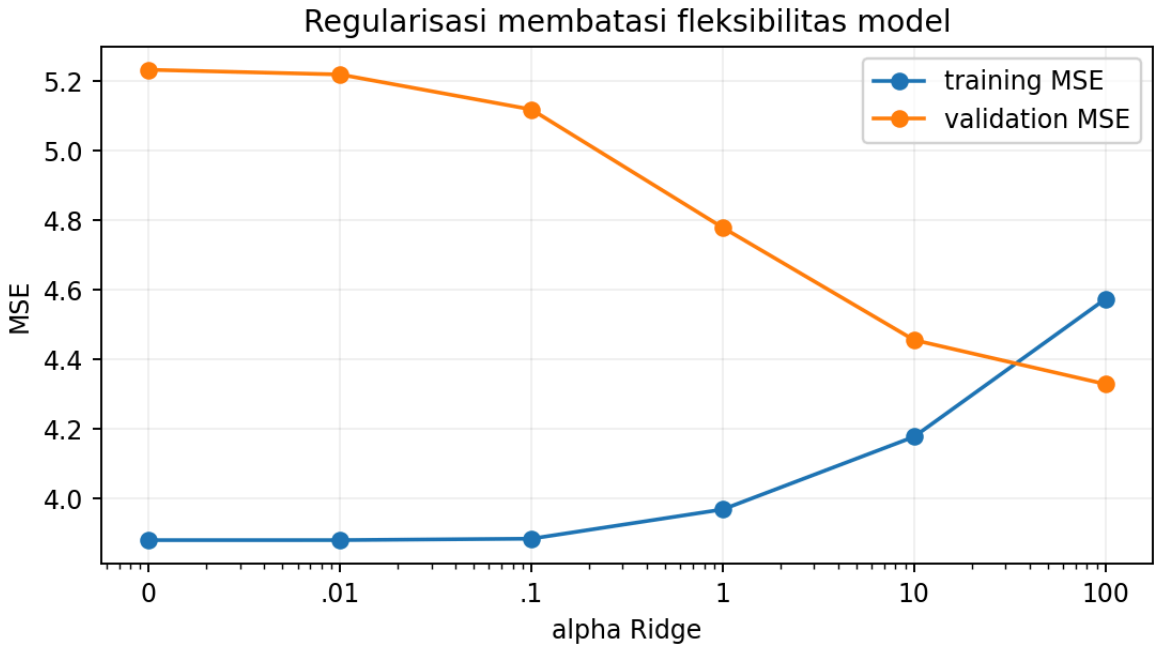
## 3.5 Regularisasi: Mengendalikan Fleksibilitas dengan Penalti

**Penjelasan teori.** Regularization menambahkan preferensi terhadap model yang lebih sederhana/stabil ke objective. Pada Ridge, koefisien besar dipenalti melalui jumlah kuadrat bobot. Efeknya adalah model bersedia menerima training error sedikit lebih besar jika hal itu membuat parameter lebih terkendali dan generalization lebih baik. Lasso menggunakan penalti absolut dan dapat mendorong beberapa koefisien menjadi nol.

**Contoh/analogi.** Analogi memilih rute: objective bukan hanya jarak tercepat, tetapi juga penalti untuk jalan sangat berisiko. Solusi sedikit lebih panjang dapat lebih robust. Regularization mengubah definisi solusi "baik" dari fit training semata menjadi fit + kompleksitas.

**Perhitungan/visualisasi.** Nilai alpha/lambda adalah hyperparameter; terlalu kecil hampir tidak membatasi model, terlalu besar dapat menyebabkan underfit.

```
Objective_Ridge = MSE + alpha * Σ_j w_j^2
```




*Gambar 3.6. Regularisasi dapat menaikkan training error tetapi menurunkan validation error sampai titik tertentu.*

## 3.6 Cross-Validation: Mengurangi Ketergantungan pada Satu Split

**Penjelasan teori.** Pada k-fold cross-validation, training data dibagi menjadi k fold. Setiap fold bergantian menjadi validation, sehingga satu konfigurasi memperoleh k nilai performance yang dapat diringkas mean dan dispersion. CV membantu ketika validation set tunggal terlalu bergantung pada satu split. Namun CV tidak memperbaiki data yang bias, dan jenis splitter harus menghormati struktur data.

**Contoh/analogi.** Analogi beberapa try-out dengan paket soal berbeda. Nilai rata-rata memberi gambaran lebih stabil daripada satu try-out, tetapi jika semua try-out berasal dari materi yang salah, hasil tetap bias.

**Perhitungan/visualisasi.** Untuk time series gunakan TimeSeriesSplit atau skema walk-forward; untuk data beberapa pasien/perangkat gunakan GroupKFold agar entitas tidak bocor antar-fold.

## 3.7 Metrik: Angka Harus Mewakili Konsekuensi Kesalahan

**Penjelasan teori.** Metrik regresi mengukur besar error dengan karakter berbeda. MAE mudah dibaca dalam satuan target dan lebih robust; RMSE lebih sensitif pada error besar; R2 membandingkan model terhadap baseline mean tetapi tidak langsung memberi besar error praktis. Pada klasifikasi, confusion matrix memisahkan TP, FP, TN, FN. Precision menjawab ketepatan prediksi positive; recall menjawab berapa positive sebenarnya berhasil ditemukan; F1 menyeimbangkan precision dan recall.

**Contoh/analogi.** Analogi alarm kebakaran: accuracy 99% dapat terlihat tinggi jika hampir semua waktu tidak ada kebakaran. Yang penting adalah apakah kejadian kebakaran benar-benar ditemukan dan berapa banyak alarm palsu yang masih dapat ditoleransi.

**Perhitungan/visualisasi.** Metrik utama harus dipilih sebelum melihat hasil sebanyak mungkin, agar kita tidak cherry-pick metric yang membuat model tampak baik.

$$\text{Precision} = TP/(TP+FP) \quad \text{Recall} = TP/(TP+FN) \quad F1 = 2PR/(P+R)$$

| Aktual/Prediksi | Pred + | Pred - |
|---|---|---|
| Aktual + | TP=18 | FN=2 |
| Aktual - | FP=12 | TN=68 |

**Praktik mini - Hitung dan tafsirkan**

1. Hitung accuracy, precision, recall, dan F1 dari confusion matrix.
2. Jika false negative 10x lebih mahal daripada false positive, pilih metrik utama dan jelaskan.
3. Tulis satu kalimat yang tidak boleh dibuat hanya dari accuracy.

## 3.8 Experiment Design dan Reproducibility

**Penjelasan teori.** Eksperimen ML yang dapat dipercaya dimulai sebelum model dijalankan: pertanyaan, dataset/version, split, baseline, kandidat model, metric, aturan pemilihan, seed, dan batas harus ditentukan. Reproducibility berarti prosedur dapat diulang; bukan jaminan bahwa prosedur tersebut benar. Catatan keputusan sama penting dengan kode karena dua notebook identik dapat menghasilkan klaim berbeda bila aturan pemilihan tidak terdokumentasi.

**Contoh/analogi.** Analogi laboratorium: peneliti tidak boleh mengganti hipotesis setelah melihat hasil tanpa menyatakan bahwa analisis bersifat eksploratif. Dalam ML, mencoba sampai test score bagus adalah bentuk data snooping.

**Perhitungan/visualisasi.** Gunakan experiment table: run ID, data version, split, feature, model, hyperparameter, metric, seed, result, interpretation.

| Elemen protokol | Contoh |
|---|---|
| Pertanyaan | Apakah Ridge meningkatkan generalisasi dibanding linear baseline? |
| Data/split | Chronological 60/20/20 |
| Baseline | Dummy mean + LinearRegression |
| Kandidat | Ridge alpha 0.1,1,10 |
| Metrik | MAE utama; RMSE pendamping |
| Aturan keputusan | Pilih validation MAE terendah; buka test sekali |
| Reproducibility | data version, seed/split, library version, preprocessing, run ID |

