

4.1 Tujuan Pembelajaran

- Menyusun EDA sebagai proses pemeriksaan pertanyaan, struktur, kualitas, pola, dan batas data.
- Mendeteksi missing values, nilai tidak valid, outlier, duplikasi, kategori tidak konsisten, dan kemungkinan leakage.
- Mencatat provenance, unit analisis, waktu pengukuran, dan definisi target.
- Melakukan fairness-aware data review tanpa mengklaim fairness hanya dari satu tabel.
- Menyusun problem-framing canvas yang menghubungkan keputusan, data, target, baseline, metrik, dan risiko.

4.2 EDA Bukan Mencari Grafik yang Menarik

Exploratory data analysis adalah proses iteratif untuk memahami apakah data dapat menjawab pertanyaan. EDA dimulai dari konteks: siapa yang mengumpulkan, untuk tujuan apa, kapan, dengan alat apa, dan apa yang tidak tercatat. Setelah itu mahasiswa memeriksa struktur, kualitas, distribusi, hubungan, serta subgroup. Grafik dipilih untuk menjawab pertanyaan tertentu dan setiap temuan diikuti kemungkinan penjelasan alternatif.

EDA harus dilakukan terutama pada training set. Melihat distribusi target test secara berulang dapat memengaruhi keputusan dan mengurangi independensi test. Pengecekan teknis minimal pada test untuk memastikan format dapat dilakukan, tetapi insight yang membentuk model sebaiknya berasal dari training dan pengetahuan domain.

Contoh data/simulasi di kelas

student_id	attendance_pct	practice_hours	internet_access	final_score	needs_support
S01	92	7	Yes	82	0
S02	58	1	No	49	1
S03	?	4	YA	64	?
S04	135	3	ya	71	0

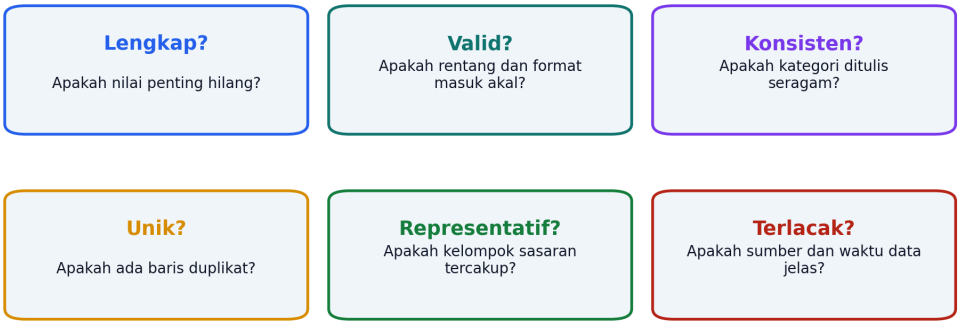
Jika EDA dilewati, model dapat dilatih pada target yang belum jelas, kolom yang belum sah, dan nilai yang melanggar domain. Pada model dasar training P3, gradient akan memperbaiki bobot terhadap sinyal yang sebenarnya campuran antara pola nyata dan kesalahan data.

Kemungkinan penanganan problem

- Tetapkan pertanyaan: keputusan apa yang ingin dibantu model?
- Tentukan unit analisis: satu baris mewakili apa?
- Tentukan target dan kapan target diketahui.
- Buat issue log: fakta, dugaan sebab, risiko algoritma, tindakan verifikasi.

4.3 Enam Pertanyaan Audit Kualitas

Audit kualitas data adalah pemeriksaan sistematis sebelum membersihkan data. Tujuannya bukan langsung memperbaiki, melainkan mengetahui masalah mana yang dapat merusak training, evaluasi, dan penggunaan model.



Gambar 4.1. Enam pertanyaan audit kualitas data.

Completeness menanyakan apakah nilai penting hilang. Validity menanyakan apakah nilai sesuai rentang dan aturan. Consistency menanyakan apakah format, satuan, dan kategori seragam. Uniqueness memeriksa duplikasi. Representativeness menanyakan apakah data mencakup kasus yang akan dihadapi. Traceability atau provenance menanyakan sumber, versi, waktu, transformasi, lisensi, dan penanggung jawab.

Contoh data

Pertanyaan audit	Contoh masalah	Risiko ke algoritma dasar
Lengkap?	practice_hours hilang 25% pada kelompok internet_access=No	Model belajar dari kelompok yang tidak seimbang
Valid?	attendance_pct=135	Loss dan bobot tertarik oleh nilai tidak sah
Konsisten?	Yes, YA, ya, ya	Encoding membuat kategori palsu
Unik?	S02 tercatat dua kali	Satu observasi memperoleh bobot ganda
Representatif?	Data hanya dari kelas pagi	Model gagal untuk kelas malam
Terlacak?	Definisi final_score tidak jelas	Klaim tidak dapat direproduksi

Jika tidak ditangani: pengaruh terhadap algoritma

Algoritma tidak mengetahui bahwa 135% adalah salah atau "YA" sama dengan "ya". Ia hanya membaca angka/kategori yang tersedia. Kesalahan kualitas menjadi sinyal palsu yang ikut mengubah bobot, intercept, dan metrik validasi.

Kemungkinan penanganan problem

- Tulis data-quality checklist sebelum cleaning.
- Bedakan data error, outlier sah, dan anomaly yang mungkin penting.
- Tentukan tindakan sementara: verifikasi, tandai, perbaiki, atau eksklusi dengan alasan.
- Jangan menghapus data tanpa mencatat efek sebelum-sesudah.

4.4 Missing Values

Nilai hilang tidak selalu acak. Missing completely at random berarti ketiadaan tidak terkait data; missing at random berarti dapat dijelaskan oleh variabel yang diamati; missing not at random berarti ketiadaan terkait nilai yang hilang atau faktor tak teramati. Kategori ini membantu berpikir, tetapi sering sulit dibuktikan hanya dari dataset. Yang penting adalah menelusuri proses pengumpulan dan melihat pola missing menurut waktu atau kelompok.

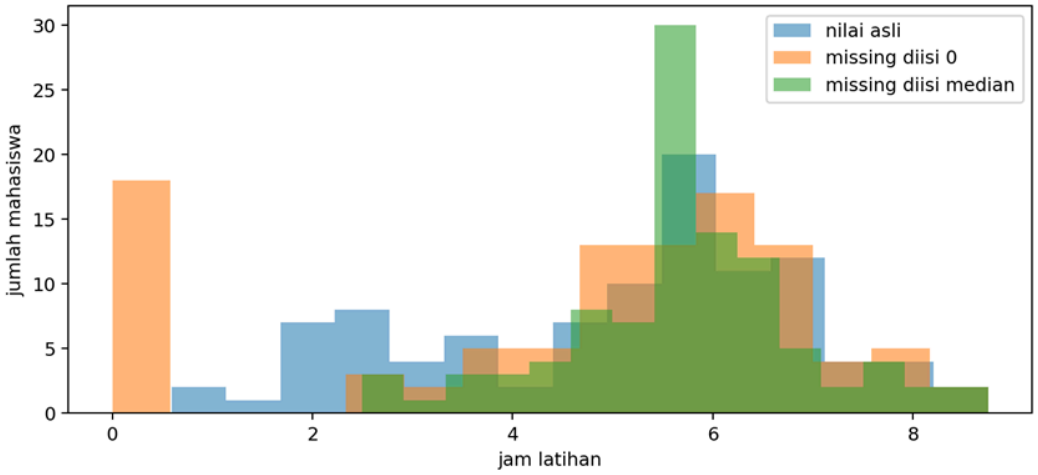
Pada kasus pendidikan, mahasiswa dengan akses internet buruk mungkin lebih sering tidak mengisi latihan; missing dapat membawa informasi proses.

Contoh data

Data	practice_hours	internet_access	needs_support
A	7	Yes	0
B	1	No	1
C	missing	No	1
D	0	Yes	0

Jika tidak ditangani: pengaruh terhadap algoritma

Mengisi missing dengan 0 menyatakan fakta baru: mahasiswa C berlatih 0 jam, padahal tidak diketahui faktanya. Jika missing banyak terjadi pada kelompok tertentu, imputasi salah dapat menggeser decision boundary dan recall kelas perlu dukungan.



Gambar 4.2. Strategi missing mengubah distribusi feature

Kemungkinan penanganan problem

- Kemungkinan 1: verifikasi sumber data; jika error pencatatan, koreksi dari sumber.
- Kemungkinan 2: impute median pada training bila missing kecil dan tidak terlalu informatif.
- Kemungkinan 3: tambahkan missing indicator bila pola missing bermakna.
- Kemungkinan 4: gunakan kategori "Tidak diketahui" untuk data kategorikal.
- Kemungkinan 5: bila fitur terlalu banyak missing dan tidak tersedia saat prediksi, hapus fitur, bukan baris.

Jangan langsung mengisi nol

Nol dapat berarti nilai nyata, sedangkan missing berarti tidak diketahui. Mengganti semua missing dengan nol dapat menciptakan fakta yang tidak pernah diukur. Strategi imputation baru dipilih pada Bab 5 setelah alasan missing didokumentasikan.

4.5 Outlier, Invalid Value, dan Anomaly

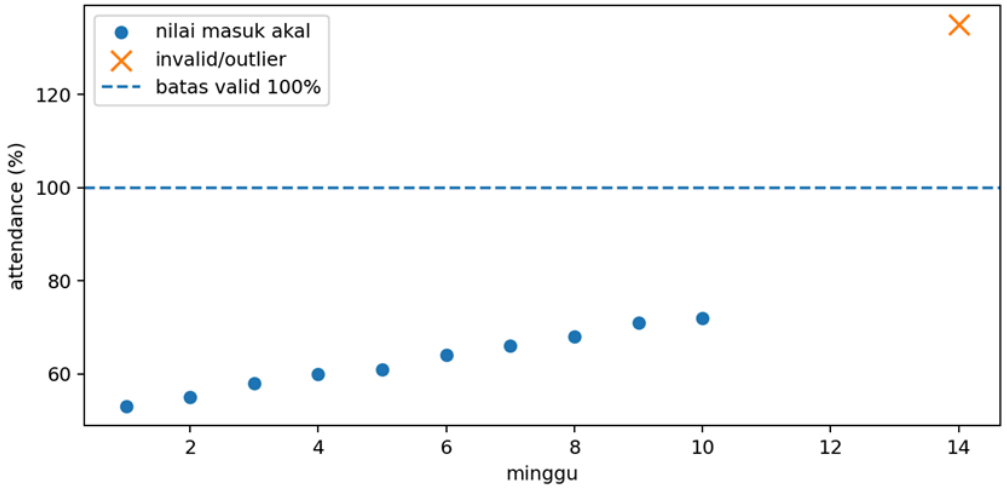
Outlier adalah observasi yang jauh dari pola umum. Invalid value melanggar aturan domain, misalnya kehadiran 135%. Anomaly adalah kasus tidak biasa yang mungkin menjadi objek penting, bukan gangguan. Nilai ekstrem tidak boleh otomatis dihapus. Prosedur yang dapat dipertanggungjawabkan adalah: identifikasi, verifikasi sumber, nilai dampak, tentukan tindakan, dan dokumentasikan sebelum-sesudah. Tindakan terhadap ketiganya harus berbeda.

Contoh data/simulasi di kelas

Kasus	Nilai	Jenis	Tindakan awal
attendance_pct=135	135%	invalid	verifikasi/koreksi/tandai
practice_hours=58	58 jam	outlier/anomaly	cek konteks; jangan langsung hapus
login_count=-3	-3	invalid	tidak mungkin; periksa pipeline
score=100	100	valid ekstrem	pertahankan jika sah

Jika tidak ditangani: pengaruh terhadap algoritma

Pada model berbasis loss, observasi ekstrem dapat memberi kontribusi loss besar sehingga update bobot mengejar kasus tersebut. Jika ekstrem adalah invalid, model belajar dari kesalahan. Jika ekstrem adalah anomaly penting, menghapusnya justru menghilangkan sinyal.



Gambar 4.3. Nilai invalid dapat menarik garis/model ke arah salah

Kemungkinan penanganan problem

- Aturan validasi domain: rentang attendance 0-100, jam tidak negatif, nilai 0-100.
- Pisahkan invalid dari outlier sah.
- Cek sensitivity: hasil model sebelum-sesudah penanganan.
- Gunakan winsorization/capping hanya bila ada alasan domain, bukan sekadar agar grafik rapi.

· Dokumentasikan keputusan: sumber, bukti, tindakan, dampak.

4.6 Duplikasi dan Kategori Tidak Konsisten

Duplikasi dapat terjadi karena penggabungan data, pencatatan ulang, atau satu entitas memiliki beberapa kejadian valid. df.duplicated() hanya menemukan baris identik; duplikasi semantik memerlukan kunci dan konteks. Kategori “Ya”, “YA”, “Y”, dan “ya ” mungkin memiliki makna sama, tetapi normalisasi harus berdasarkan kamus data. Jangan menggabungkan kategori berbeda hanya karena ejaannya mirip.

Contoh data/simulasi di kelas

student_id	internet_access	program_track	needs_support
S01	Yes	Software	0
S01	Yes	Software	0
S02	yes	software	1
S03	YA	Software Eng.	0

Jika tidak ditangani: pengaruh terhadap algoritma

Duplikasi S01 memperbesar pengaruh pola S01 dalam objective. Variasi "Yes", " yes ", dan "YA" membuat encoding bertambah kolom, data menjadi jarang, dan model sulit belajar pola stabil.

Kemungkinan penanganan problem

· Gunakan key: student_id + periode + course untuk mendeteksi duplicate entity.

· Bedakan duplicate row dan kejadian valid berulang.

· Normalisasi kategori dengan kamus data: strip whitespace, case folding, mapping resmi.

· Jangan menyatukan kategori yang berbeda secara semantik hanya karena mirip teks.

4.7 Provenance dan Fairness-Aware Review

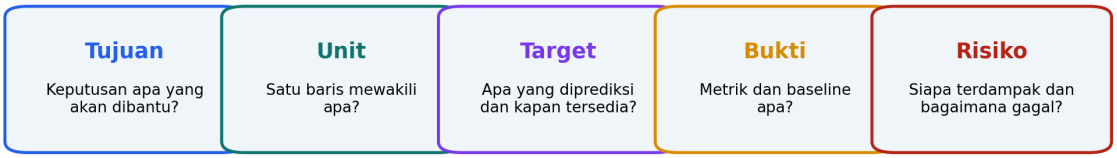
Provenance menjawab dari mana data berasal dan transformasi apa yang telah terjadi. Catatan minimal mencakup pemilik, lisensi, tanggal, unit analisis, cara sampling, definisi kolom, rentang waktu, versi, dan transformasi. Tanpa provenance, evaluasi sulit direproduksi dan perubahan distribusi sulit dijelaskan.

Fairness-aware review bukan satu rumus. Mahasiswa memeriksa apakah kelompok terdampak terwakili, missing dan error berbeda antarkelompok, target merupakan proxy yang bermasalah, dan kesalahan model memiliki dampak yang tidak simetris. Pada dataset sintetis, internet_access digunakan untuk mendiskusikan kesenjangan akses, bukan untuk membuat keputusan nyata atau menyimpulkan kondisi sosial mahasiswa.

Bahasa yang hati-hati

Hindari “kelompok A lebih buruk” hanya dari rata-rata. Tulis: “Pada sampel ini terdapat perbedaan deskriptif yang memerlukan pemeriksaan ukuran kelompok, sebaran, proses sampling, confounder, dan ketidakpastian.”

4.8 Problem Framing Setelah Literasi Data



Framing dimulai setelah mahasiswa mengenal fitur, target, kualitas data, dan evaluasi.

Framing menetapkan batas sistem dan konsekuensi penggunaan, bukan sekadar judul proyek.

Gambar 4.2. Urutan problem framing yang berpijak pada pemahaman data.

Problem framing mengubah persoalan dunia nyata menjadi tugas yang dapat diuji tanpa kehilangan tujuan dan konsekuensinya. Framing yang baik tidak dimulai dari pertanyaan “algoritma apa”, melainkan dari keputusan yang hendak dibantu. Model adalah satu komponen dalam proses, bukan tujuan akhir.

Elemen canvas	Pertanyaan	Contoh sintetis
Tujuan dan pengguna	Keputusan apa yang dibantu, oleh siapa?	Memberi sinyal awal agar dosen menawarkan dukungan, bukan menghukum.
Unit analisis	Satu baris mewakili apa?	Satu mahasiswa pada satu periode sebelum ujian akhir.
Target dan horizon	Apa yang diprediksi dan kapan?	needs_support sebelum nilai akhir tersedia.
Fitur tersedia	Apa yang legal dan tersedia saat prediksi?	Kehadiran, nilai prasyarat, latihan; bukan final_score.
Baseline	Apa pembanding paling sederhana?	Kelas mayoritas dan aturan berbasis ambang yang transparan.
Metrik	Kesalahan mana yang lebih berbahaya?	Recall kelas needs_support plus precision, F1, dan balanced accuracy.
Risiko dan batas	Siapa terdampak; bagaimana gagal?	False positive menambah beban; false negative kehilangan dukungan.
Tindakan	Apa yang terjadi setelah prediksi?	Tinjauan manusia dan tawaran dukungan sukarela.

Pada kasus pendidikan, prediksi tidak boleh langsung menjadi sanksi atau keputusan berisiko tinggi. Dataset latihan bersifat sintetis dan digunakan untuk belajar prosedur. Problem framing harus menyatakan batas penggunaan dan kebutuhan human oversight. Kemampuan menyebutkan kapan model tidak boleh dipakai adalah bagian kompetensi, bukan tanda kegagalan proyek.

4.9 Ringkasan

- EDA menghubungkan konteks, struktur, kualitas, pola, dan batas data.
- Missing, outlier, duplikasi, dan kategori tidak konsisten harus ditelusuri sebelum diperbaiki.
- Provenance memungkinkan reproduksi dan penilaian kesesuaian data.
- Fairness review memeriksa representasi, kualitas, target, dan konsekuensi menurut kelompok.
- Problem framing menetapkan keputusan, unit, target, waktu, fitur, baseline, metrik, tindakan, dan risiko.

4.10 Cek Pemahaman

1. Mengapa EDA terutama dilakukan pada training set?
2. Bedakan outlier, invalid value, dan anomaly.
3. Apa risiko mengganti semua missing dengan nol?
4. Apa bukti minimal yang diperlukan sebelum menyatakan dataset tidak adil?
5. Mengapa final_score merupakan leakage untuk prediksi needs_support sebelum ujian akhir?

Bacaan utama

• Géron, Edisi 3, Bab 2: explore and visualize data, data preparation, checking assumptions.
• James dkk., ISLP, Bab 2 dan Lab data exploration.
• Molnar, versi 2019: Importance of Interpretability dan pengantar risiko sampling, data encoding, feature engineering, fairness, reliability, dan debugging.

