

5.1 Tujuan Pembelajaran

- Membedakan cleaning, imputation, encoding, scaling, dan feature engineering berdasarkan tujuan transformasinya.
- Menjelaskan sifat metode imputasi, encoding, scaling, dan penanganan imbalance serta konsekuensinya terhadap representasi X, loss, gradient, dan evaluasi.
- Menerapkan prinsip split-before-fit: semua statistik yang “dipelajari dari data” berasal dari training.
- Menjelaskan fungsi konseptual ColumnTransformer dan Pipeline pada data campuran tanpa menjadikannya sekadar sintaks library.
- Mendeteksi target leakage, train-test contamination, duplicate/group leakage, temporal leakage, resampling leakage, dan tuning leakage.
- Mengevaluasi class imbalance dengan baseline, confusion matrix, recall, precision, F1, balanced accuracy, dan konsekuensi kesalahan.

5.2 Cleaning Tidak Sama dengan Preprocessing

Cleaning memperbaiki atau menandai data yang tidak sesuai definisi, misalnya kategori tidak konsisten, unit salah, atau duplikasi. Preprocessing mengubah representasi agar dapat dipakai algoritma, misalnya mengisi missing, one-hot encoding, dan scaling. Feature engineering membangun fitur baru berdasarkan pengetahuan domain. Ketiga aktivitas dapat beririsan, tetapi alasannya harus dibedakan agar transformasi dapat diaudit.

Aktivitas	Pertanyaan utama	Contoh
Cleaning	Apakah data sesuai definisi dan pencatatan?	"YA", "ya ", dan "Y" diverifikasi lalu dinormalisasi menjadi kategori yang sama.
Preprocessing	Bagaimana data sah direpresentasikan untuk algoritma?	Missing diimputasi, kategori di-encode, fitur numerik di-scale.
Feature engineering	Apakah representasi baru membantu tujuan?	Rasio latihan selesai / latihan tersedia, jika valid secara domain.

5.3 Prinsip Split-Before-Fit

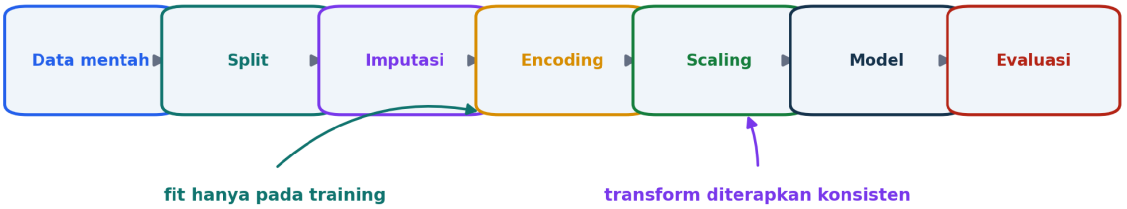
Langkah pertama setelah target dan fitur ditetapkan adalah memisahkan data training dan test. Imputer, scaler, feature selector, dan encoder kemudian di-fit hanya pada training. Validation/test hanya ditransformasi menggunakan parameter yang telah dipelajari dari training. Menghitung mean seluruh data sebelum split membuat informasi agregat test bocor ke training, walaupun target tidak digunakan secara langsung.

Contoh data

Langkah salah	Mengapa bocor	Langkah benar
fit scaler pada seluruh data	mean/std test ikut membentuk training	split dulu, scaler.fit(X_train)
fit imputer seluruh data	median test ikut diketahui	imputer.fit(X_train)
pilih fitur seluruh data	target validation/test memengaruhi fitur	selector di dalam CV/pipeline

Walaupun target tidak dipakai langsung, statistik test yang masuk ke preprocessing membuat representasi training lebih mirip test. Evaluasi menjadi terlalu optimistis dan gagal saat deployment. Kemungkinan penanganan problem :

- Tulis urutan: define target → X/y → split → FIT preprocessing pada train → TRANSFORM train/validation/test → training → evaluasi.
- Gunakan pipeline agar urutan tidak terlupa. Pipeline menyimpan urutan dan mencegah langkah terlewat saat validasi atau prediksi baru.
- Dalam cross-validation, transformasi harus fit ulang di tiap training fold.



Gambar 5.1. Urutan pipeline yang dapat direproduksi dengan fit hanya pada training.

Objek	Apa yang dipelajari	Mengapa test tidak boleh ikut fit
Mean/median imputer	nilai pengganti	statistik test akan memengaruhi representasi training
One-hot encoder	daftar kategori training	kategori test tidak boleh menentukan kolom training
Standardization	mean dan SD training	skala test tidak boleh membentuk skala training
Min-max	minimum dan maksimum training	rentang test tidak boleh diketahui sebelumnya
Robust scaling	median dan IQR training	distribusi test tidak boleh ikut menentukan pusat/sebaran
Class weight dari data	proporsi kelas training	komposisi test tidak boleh mengubah objective training

Kaitan dengan P3
Jika X berubah karena preprocessing, score z = b + Xw, prediction, loss, gradient, dan akhirnya weight juga berubah. Preprocessing bukan kosmetik sebelum algoritma; ia mengubah data yang benar-benar dilihat optimizer.

5.4 Imputation

Imputation mengisi nilai hilang berdasarkan aturan yang dipelajari dari training. Median sering dipakai untuk numerik karena lebih robust; most_frequent dapat dipakai untuk kategorikal; constant dapat menambahkan kategori “Tidak diketahui”. Pilihan bukan sekadar teknis. Imputation dapat mengecilkan variasi, mengubah hubungan, dan menyamarkan pola missing. Pada beberapa kasus, indikator missing

memberi informasi tambahan, tetapi dapat pula menjadi proxy proses yang tidak adil. Setiap metode dapat mengubah pusat, sebaran, korelasi, serta representasi subgroup.

5.4.1 Menghapus baris (complete-case)

Sifat: tidak membuat nilai baru, tetapi mengurangi jumlah observasi. Masuk akal bila missing sangat sedikit, mekanisme kehilangan cukup masuk akal, dan penghapusan tidak menghilangkan kelompok tertentu secara tidak proporsional. Risiko utama adalah kehilangan informasi dan bias representasi.

Data awal	Setelah drop
S1: 72, y=0	dipakai
S2: missing, y=1	dihapus
S3: 80, y=0	dipakai

Dampak ke training: jika missing lebih banyak pada kelas positif, drop row membuat optimizer melihat lebih sedikit positive example. Loss tampak mudah turun, tetapi recall kelas penting dapat memburuk.

5.4.2 Mean imputation untuk numerik

Sifat: mengganti missing dengan mean training. Cocok untuk data numerik yang relatif simetris tanpa outlier ekstrem dan bila missing tidak terlalu dominan. Mean menggunakan seluruh nilai sehingga sensitif terhadap outlier. Semua nilai yang hilang ditempatkan di titik yang sama sehingga variasi dapat mengecil.

Nilai training	30	35	40	45	300	Mean
study_hours	30	35	40	45	300	90

Pada contoh sangat miring di atas, mean = 90. Jika missing sebenarnya berasal dari mahasiswa dengan pola 30–45, imputasi 90 menciptakan representasi yang tidak wajar.

5.4.3 Median imputation untuk numerik

Sifat: mengganti missing dengan median training. Lebih robust terhadap nilai ekstrem karena bergantung pada urutan, bukan besar absolut semua nilai. Cocok untuk distribusi miring atau data dengan outlier. Risiko: tetap mengurangi variasi dan dapat menghilangkan sinyal missing.

Data training	Mean	Median	Implikasi
30, 35, 40, 45, 300	90	40	Median lebih dekat pusat mayoritas observasi; mean tertarik outlier.

5.4.4 Mode/most-frequent untuk kategorikal

Sifat: mengganti missing dengan kategori yang paling sering muncul di training. Praktis bila satu kategori jelas dominan dan missing kecil. Risiko: memperbesar dominasi kategori mayoritas dan menyamarkan bahwa nilai semula tidak diketahui.

program_track	Software	Software	Data	missing	Software
Mode training	Software				

5.4.5 Constant / kategori “Unknown”

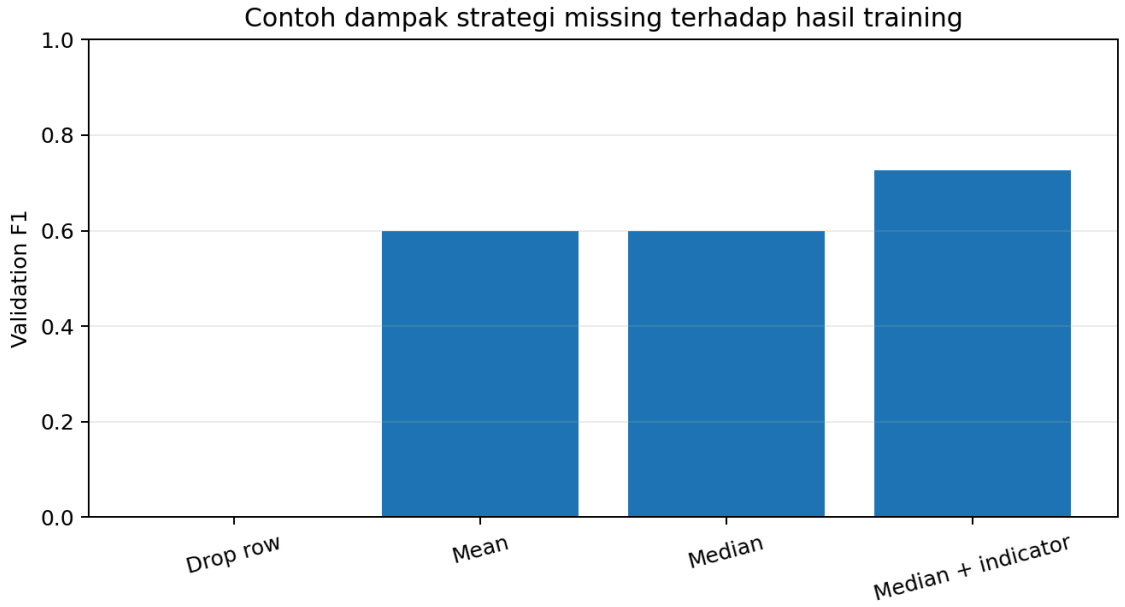
Sifat: missing kategorikal diberi kategori eksplisit, misalnya “Unknown”. Kelebihannya, kita tidak memaksa missing menjadi kategori yang benar-benar diamati. Cocok bila “tidak diketahui” sendiri perlu dipertahankan sebagai keadaan data. Risiko: kategori Unknown dapat menjadi proxy proses pengumpulan atau kondisi tertentu dan harus diaudit.

5.4.6 Missing indicator

Sifat: menambah fitur biner yang menandai nilai semula missing. Biasanya digabung dengan imputasi numerik. Berguna bila mekanisme missing membawa informasi prediktif. Risiko: model dapat belajar proses administrasi/pencatatan alih-alih fenomena substantif.

study_hours asli	setelah median	study_missing
missing	40	1
40	40	0

Walaupun kedua observasi memperoleh nilai numerik yang sama setelah imputasi, indicator mempertahankan fakta bahwa salah satunya semula tidak tercatat.



Gambar 5.2. Contoh terkontrol: strategi missing dapat menghasilkan training/evaluasi berbeda karena X yang masuk ke model berbeda.

> Prinsip pemilihan imputasi
> Jangan memilih metode karena “paling umum”. Pertanyakan: bentuk distribusi, ada/tidak outlier, apakah missing informatif, apakah subgroup tertentu lebih sering missing, dan bagaimana hasil validation berubah. Test tidak dipakai untuk memilih strategi.

5.5 Encoding Kategorikal

Model numerik memerlukan representasi angka. One-hot encoding membuat satu indikator per kategori dan tidak memaksakan urutan. Ordinal encoding hanya layak jika urutan benar-benar bermakna.

5.5.1 Binary mapping

Untuk kategori yang benar-benar memiliki dua keadaan, mapping 0/1 dapat digunakan, misalnya No=0 dan Yes=1. Angka 0/1 di sini menyatakan dua keadaan, bukan bahwa Yes “dua kali lebih besar”. Pastikan definisi positif konsisten.

5.5.2 One-hot encoding untuk nominal

One-hot membuat satu kolom indikator untuk setiap kategori training. Cocok untuk kategori nominal tanpa urutan, seperti program_track = Software, Data, Network. Kelebihan: tidak memaksakan urutan. Kekurangan: dimensi bertambah; kategori baru perlu aturan seperti all-zero/Unknown.

program_track	software	data	network
Software	1	0	0
Data	0	1	0
Network	0	0	1

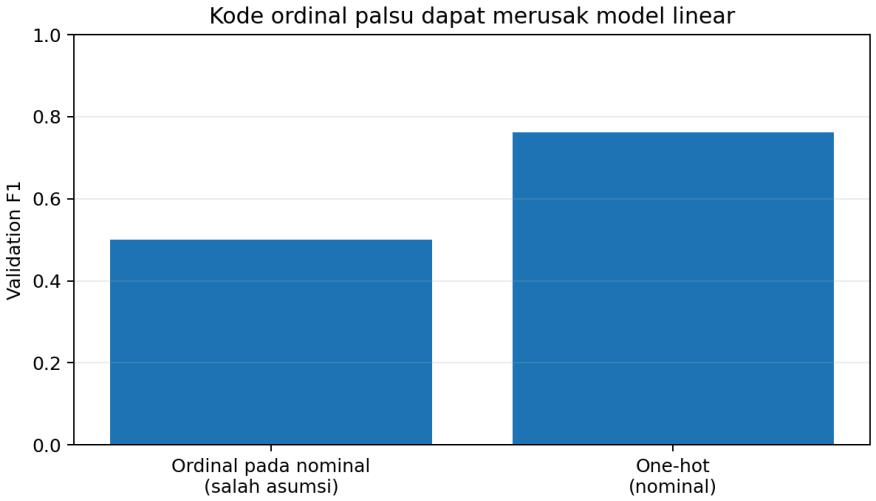
5.5.3 Ordinal encoding untuk kategori berurutan

Ordinal encoding layak bila urutannya memang bermakna, misalnya Low < Medium < High. Mapping 0,1,2 menyimpan urutan. Tetapi selisih satu angka juga membawa asumsi jarak yang kurang lebih sama; jika hal itu tidak masuk akal, interpretasi weight harus hati-hati.

engagement_level	Kode
Low	0
Medium	1
High	2

5.5.4 Mengapa ordinal salah berbahaya untuk kategori nominal?

Jika Software=1, Data=2, Network=3, model linear membaca satu sumbu berurutan. Model hanya dapat belajar hubungan monotonic terhadap kode tersebut. Jika Software dan Network sama-sama berisiko tinggi tetapi Data rendah, satu weight ordinal tidak dapat merepresentasikan pola “tinggi-rendah-tinggi” dengan baik.



5.6 Scaling

Standardization mengurangi mean training dan membagi standard deviation training sehingga fitur berada pada skala relatif serupa. Min-max scaling memetakan rentang training ke interval tertentu, tetapi sensitif outlier. Model berbasis jarak, gradient, atau regularization biasanya peka skala. Pohon keputusan umumnya tidak memerlukan scaling untuk split, tetapi pipeline konsisten tetap penting ketika beberapa model dibandingkan.

$$z = (x - \mu_train) / \sigma_train$$

Mean dan standard deviation harus berasal dari training set, bukan seluruh data.

5.6.1 Standardization

$$z = (x - mean_train) / SD_train$$

Sifat: pusat training menjadi sekitar 0 dan SD sekitar 1. Cocok sebagai default untuk gradient-based linear/logistic models dan regularization ketika feature berskala berbeda. Tidak membatasi nilai ke 0–1 dan masih dipengaruhi outlier karena mean/SD sensitif.

5.6.2 Min-max scaling

$$x_scaled = (x - min_train) / (max_train - min_train)$$

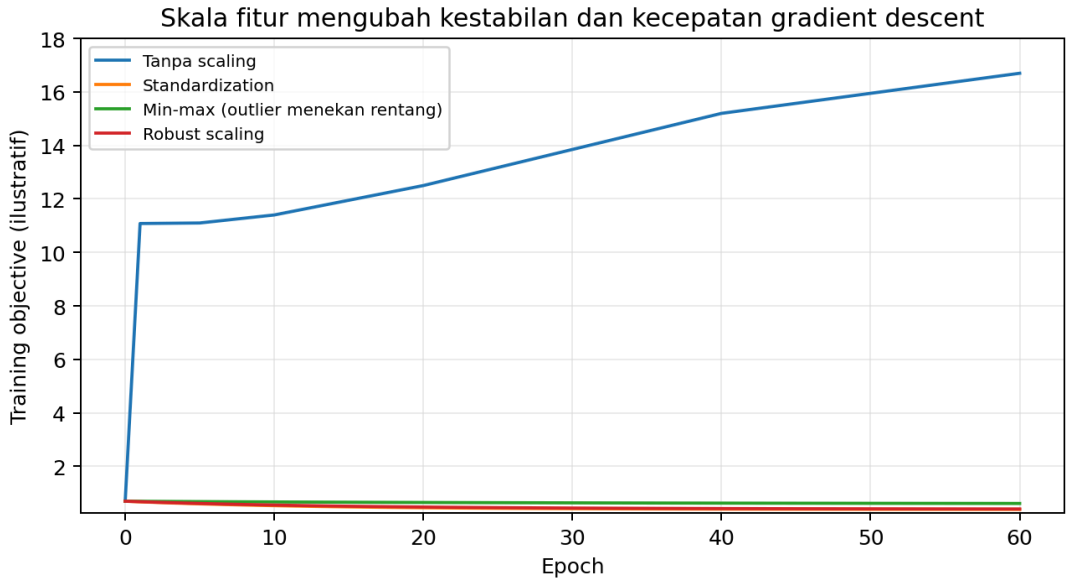
Sifat: memetakan rentang training ke sekitar 0–1. Mudah dipahami dan mempertahankan urutan relatif. Sangat sensitif terhadap minimum/maksimum ekstrem: satu outlier besar dapat memampatkan mayoritas observasi ke rentang sangat sempit.

5.6.3 Robust scaling

$$x_robust = (x - median_train) / IQR_train$$

Sifat: menggunakan median dan IQR sehingga lebih tahan terhadap outlier. Cocok ketika distribusi numerik sangat miring/ekstrem. Bukan jaminan model lebih baik; ia hanya membuat representasi tidak terlalu dikuasai nilai ekstrem.

Metode	Pusat/skala	Kuat terhadap outlier?	Catatan
Standardization	mean + SD	Sedang/rendah	baik untuk gradient dan regularization; nilai tidak dibatasi
Min-max	min + range	Rendah	outlier dapat memampatkan mayoritas data
Robust	median + IQR	Lebih tinggi	berguna untuk distribusi miring/outlier



Gambar 5.3. Dengan learning rate yang sama, representasi skala dapat membuat gradient descent stabil, lambat, atau tidak stabil.

5.7 ColumnTransformer dan Pipeline

Dataset nyata sering berisi numerik, nominal, ordinal, dan binary sekaligus. Secara konseptual, ColumnTransformer adalah router: setiap kelompok kolom masuk ke transformasi yang sesuai, lalu hasilnya digabung. Pipeline adalah urutan keadaan: fit preprocessing pada training, transform, fit model, kemudian ulangi transformasi yang sama untuk data baru.

Kolom contoh	Jenis	Transformasi yang sesuai	State yang dipelajari dari train
attendance_pct	Numerik	median imputation + standardization	median, mean, SD
study_hours_week	Numerik miring	median imputation + robust/standard sesuai eksperimen	median, IQR atau mean, SD
program_track	Nominal	mode/Unknown + one-hot	mode + daftar kategori training
engagement_level	Ordinal	mode + ordinal mapping yang ditetapkan domain	mode; mapping domain
internet_access	Binary	mapping No/Yes	definisi mapping

Data mentah → SPLIT → [cabang numerik | nominal | ordinal | binary] → gabungkan X → training manual → evaluasi

Contoh operasional nyata
Pada sistem early-support kampus, attendance dan prior_score adalah numerik; program_track nominal; engagement_level ordinal; internet_access binary. Tanpa "router", mudah terjadi kesalahan seperti memberi ordinal palsu pada program_track atau memakai scaler pada kolom kategori. Pipeline mencegah urutan fit/transform berubah antara training dan prediksi baru.

Fit, transform, dan fit_transform

Operasi	Makna konseptual
fit(train)	pelajari state preprocessing dari training saja
transform(data)	gunakan state yang sudah dipelajari; tidak belajar ulang
fit_transform(train)	fit state pada training lalu transform training
transform(validation/test/new)	gunakan state training yang sama

```
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.linear_model import LogisticRegression

numeric_pipe = Pipeline([
    ('imputer', SimpleImputer(strategy='median')),
    ('scaler', StandardScaler())
])

categorical_pipe = Pipeline([
    ('imputer', SimpleImputer(strategy='most_frequent')),
    ('onehot', OneHotEncoder(handle_unknown='ignore'))
])

preprocess = ColumnTransformer([
    ('num', numeric_pipe, numeric_columns),
    ('cat', categorical_pipe, categorical_columns)
])

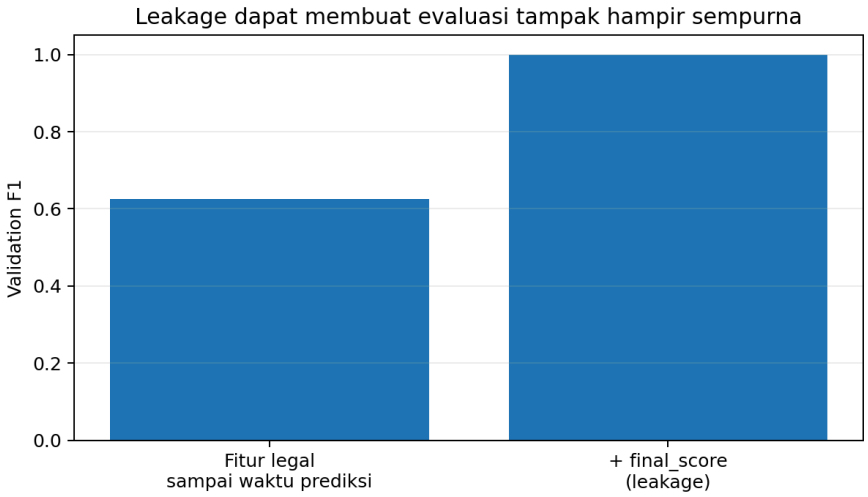
model = Pipeline([
    ('preprocess', preprocess),
    ('classifier', LogisticRegression(max_iter=1000))
])
```

Contoh 6.2. Pipeline numerik dan kategorikal.

5.8 Data Leakage

Leakage terjadi ketika informasi yang tidak seharusnya tersedia ikut membentuk fitur, preprocessing, pemilihan model, atau evaluasi. Gradient descent tetap menjalankan rumus dengan benar; yang salah adalah batas informasi eksperimen.

Jenis leakage	Contoh operasional	Mengapa menipu	Kontrol
Target leakage	final_score dipakai untuk prediksi needs_support pada minggu ke-8	fitur membawa jawaban masa depan	tetapkan waktu prediksi; keluarkan fitur pasca-outcome
Train-test contamination	median/scaler dihitung dari seluruh data sebelum split	state preprocessing sudah melihat distribusi test	split dahulu; fit state pada train
Temporal leakage	actual_delivery_hours untuk memprediksi keterlambatan saat dispatch	informasi baru tersedia setelah kejadian	audit timestamp; split waktu bila perlu
Duplicate/group leakage	rekaman mesin/pasien/mahasiswa yang sama masuk train dan test	model melihat entitas hampir sama pada kedua sisi	deduplikasi/split per group
Resampling leakage	minority di-oversample sebelum split	salinan/sangat mirip dapat masuk validation/test	resampling training saja
Tuning leakage	test dibuka berulang untuk memilih threshold/model	test berubah fungsi menjadi validation	kunci keputusan; test dibuka terakhir



Gambar 5.4. Contoh early-support sintetis: memasukkan final_score dapat membuat validation F1 tampak sempurna, justru menjadi tanda audit.

Tanda peringatan
Skor hampir sempurna pada masalah yang secara domain sulit bukan alasan langsung untuk merayakan model. Audit timestamp, fitur turunan target, duplicate/group, preprocessing sebelum split, resampling, dan penggunaan test.

5.9 Class Imbalance

Class imbalance berarti jumlah contoh antarkelas tidak seimbang. Masalah utamanya bukan ketidakseimbangan semata, tetapi apakah kelas yang jarang penting dan apakah model mengabaikannya. Langkah pertama adalah baseline dan metrik yang tepat. Penanganan dapat berupa class_weight, over-sampling, under-sampling, threshold adjustment, atau pengumpulan data. Resampling hanya dilakukan pada training fold, tidak sebelum split.

Misalkan 180 observasi kelas 0 dan hanya 20 kelas 1. Model yang selalu menjawab 0 memiliki accuracy 90%, tetapi recall kelas 1 = 0. Karena itu penanganan imbalance dimulai dari baseline dan metrik, bukan langsung “menyeimbangkan data”. Balanced accuracy merata-ratakan recall setiap kelas. F1 positive menyeimbangkan precision dan recall kelas positive. Tidak ada metrik tunggal yang selalu benar. Laporan harus menyertakan confusion matrix, ukuran kelas, definisi positive, threshold, dan konsekuensi kesalahan.

5.9.1 Threshold adjustment

Sifat: tidak mengubah training data atau weight; hanya mengubah probability menjadi keputusan kelas. Menurunkan threshold biasanya menaikkan recall dan false positive. Cocok ketika trade-off keputusan perlu diatur dari validation.

5.9.2 Class weighting

Sifat: training data tidak diduplikasi. Loss/gradient observasi kelas penting diberi bobot lebih besar. Efeknya decision boundary terdorong agar kesalahan kelas minoritas lebih mahal. Risiko: false positive dapat meningkat; bobot terlalu besar dapat membuat model terlalu agresif.

$$\text{Objective} = \text{weighted mean}(\text{BCE}_i) + \text{regularization}$$

5.9.3 Random oversampling

Sifat: duplikasi acak observasi minoritas hanya di training sampai proporsinya lebih seimbang. Mudah dipahami dan tidak membuang data mayoritas. Risiko: model dapat terlalu sering melihat contoh minoritas yang sama dan overfit. Harus dilakukan setelah split dan hanya di training.

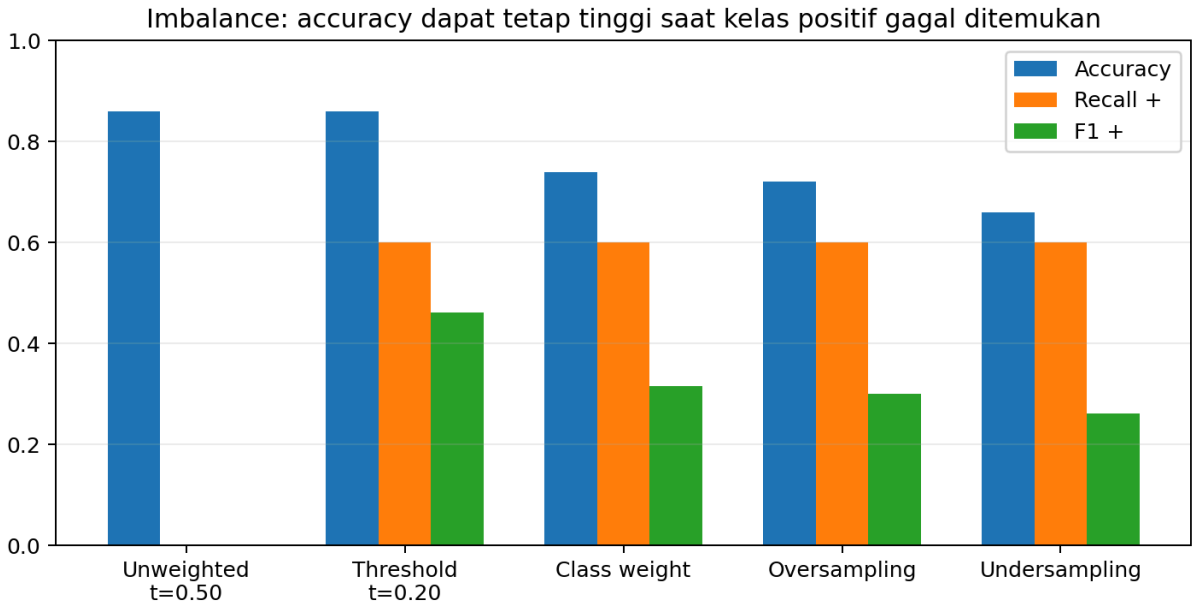
5.9.4 Random undersampling

Sifat: mengurangi observasi mayoritas secara acak. Training lebih ringan dan kelas lebih seimbang. Risiko utamanya kehilangan informasi mayoritas, terutama bila dataset kecil atau mayoritas heterogen.

5.9.5 Pengumpulan data tambahan

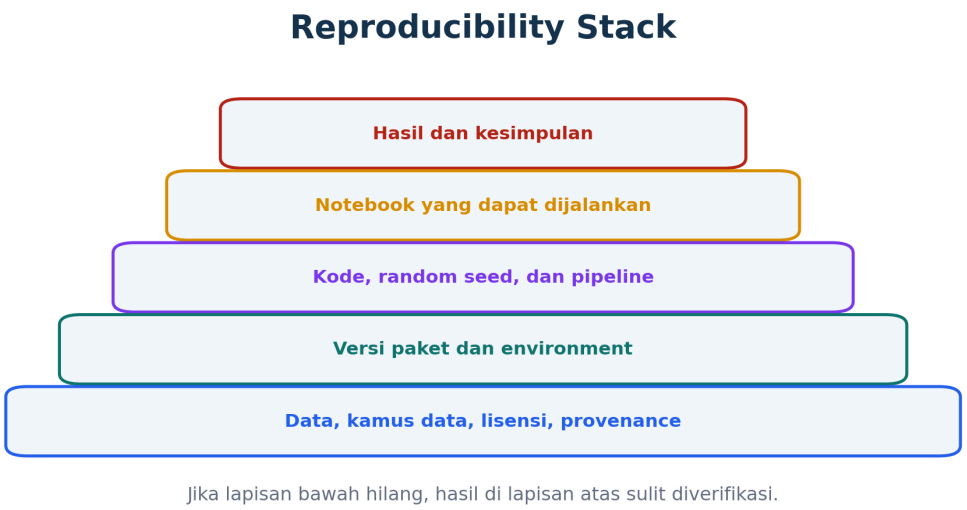
Jika memungkinkan, menambah contoh minoritas yang valid sering lebih baik daripada manipulasi statistik. Namun data baru harus berasal dari populasi sasaran dan proses pengumpulan yang sah; banyak data dari sumber bias tidak menyelesaikan representativeness.

Metode	Mengubah data training?	Mengubah objective?	Mengubah threshold?	Risiko utama
Threshold	Tidak	Tidak	Ya	FP/FN trade-off
Class weight	Tidak	Ya	Tidak	terlalu agresif pada minoritas
Oversampling	Ya: tambah minoritas	Secara efektif ya melalui frekuensi	Tidak	overfit duplicate minoritas
Undersampling	Ya: kurangi mayoritas	Secara efektif ya melalui komposisi	Tidak	kehilangan informasi mayoritas
Tambah data	Ya: data nyata baru	Tidak langsung	Tidak	sampling bias baru



Gambar 5.5. Contoh: accuracy saja dapat menutupi recall kelas positif yang nol; penanganan mengubah trade-off, bukan menjamin semua metrik naik.

5.10 Reproducibility dan Privacy Dasar



Gambar 5.6. Lapisan artefak yang mendukung reproducibility.

Reproducibility berarti orang lain—atau diri sendiri beberapa minggu kemudian—dapat menjalankan prosedur yang sama dan memahami perbedaan hasil. Simpan data atau referensinya, data dictionary, notebook yang dapat dijalankan berurutan, environment, random seed, split strategy, pipeline, metrik, serta catatan keputusan. Reproducibility bukan jaminan kebenaran; eksperimen yang salah juga dapat direproduksi.

Privacy harus dipikirkan sejak data diperoleh. Gunakan data minimum yang diperlukan, pisahkan identifier, batasi akses, hindari menampilkan baris individu pada laporan publik, dan pahami izin/lisensi. Anonimisasi sederhana belum tentu cukup karena kombinasi fitur dapat mengidentifikasi ulang. Dataset sintetis pada paket ini menghindari penggunaan data mahasiswa nyata.

5.11 Ringkasan

- Imputasi mengisi representasi yang hilang; metode yang berbeda mengubah pusat, sebaran, dan sinyal missing secara berbeda.
- Encoding harus mencerminkan struktur kategori yang benar; one-hot untuk nominal, ordinal hanya untuk urutan yang benar-benar bermakna.
- Scaling memengaruhi besar gradient dan regularization; standard, min-max, dan robust mempunyai sifat berbeda terhadap outlier.
- ColumnTransformer memisahkan cabang transformasi; Pipeline menjaga urutan fit/transform dan batas informasi training.
- Leakage membuat evaluasi terlalu optimistis walaupun kode dan matematika training benar.
- Imbalance tidak diselesaikan oleh satu metode universal; baseline, recall/precision/F1, threshold, class weight, dan resampling harus dibaca sebagai trade-off.

5.12 Cek Pemahaman

1. Mengapa median biasanya lebih aman daripada mean pada data numerik yang sangat miring dengan outlier?
2. Kapan constant “Unknown” lebih informatif daripada most-frequent untuk kategori missing?

3. Mengapa program_track tidak boleh diberi kode Software=1, Data=2, Network=3 tanpa dasar urutan?
4. Apa perbedaan Standardization, Min-max, dan Robust scaling dari sisi state yang dipelajari dan sensitivitas outlier?
5. Mengapa transformer harus fit hanya pada training?
6. Jelaskan fungsi ColumnTransformer dan Pipeline tanpa menyebut sintaks library.
7. Berikan satu contoh target leakage dan satu contoh train-test contamination.
8. Mengapa accuracy 90% dapat buruk pada data 90:10?
9. Apa perbedaan mekanisme class weighting dan oversampling terhadap training?

Bacaan utama

- Géron, Hands-On Machine Learning, Edisi 3, Bab 2–3.
- James dkk., An Introduction to Statistical Learning with Applications in Python, Bab 5 dan bagian preprocessing/model assessment yang relevan.
- Molnar, Interpretable Machine Learning: perspektif debugging, data/feature issues, fairness, dan reliability.

