

6.1 Tujuan Pembelajaran

- Menjelaskan relevansi, redundansi, dan konsekuensi terlalu banyak fitur.
- Membedakan feature selection dari feature extraction.
- Membandingkan pendekatan filter, wrapper, dan embedded pada tingkat pengantar.
- Menjelaskan PCA sebagai rotasi/proyeksi ke arah varians besar dan membaca explained variance.
- Mengevaluasi trade-off antara kinerja, kompresi, stabilitas, dan interpretabilitas.
- Menulis representation-risk note yang mencatat informasi dan kelompok yang mungkin hilang.

6.2 Mengapa Mengurangi Fitur

Fitur yang tidak relevan menambah noise dan biaya. Fitur sangat berkorelasi dapat redundan. Banyak fitur meningkatkan dimensi ruang dan membuat data semakin jarang, sehingga model berisiko overfit dan jarak menjadi kurang informatif. Mengurangi fitur dapat mempercepat training, mengurangi memori, meningkatkan stabilitas, dan memudahkan penjelasan. Namun pengurangan yang agresif dapat membuang sinyal kelas minoritas atau informasi penting bagi subgroup.

Tiga pertanyaan sebelum mengurangi fitur

1) Apakah fitur membawa informasi? 2) Apakah informasinya sudah diwakili fitur lain? 3) Jika dihapus/ditransformasi, apakah makna keputusan masih dapat dijelaskan?

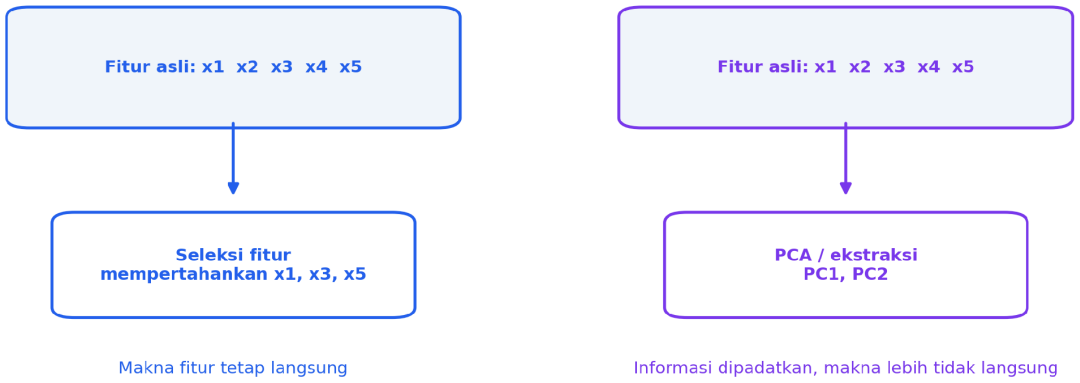
Contoh data awal: 5 mahasiswa

ID	study_hours	practice_count	attendance_pct	random_noise	constant_feature	final_score
M1	1	2	70	9	1	55
M2	2	4	85	1	1	60
M3	3	6	75	6	1	72
M4	4	8	90	2	1	78
M5	5	10	80	8	1	90

Pada contoh ini, `study_hours` dan `practice_count` bergerak bersama secara sempurna; `constant_feature` selalu bernilai 1; `random_noise` sengaja dibuat tidak berhubungan kuat dengan nilai akhir.

6.3 Feature Selection dan Feature Extraction

Feature selection memilih sebagian fitur asli. Makna kolom tetap dapat dirujuk langsung, misalnya memilih attendance_pct dan prior_score. Feature extraction membentuk representasi baru dari kombinasi fitur, misalnya principal components. Representasi baru dapat lebih ringkas tetapi maknanya tidak selalu mudah dijelaskan. Pilihan tergantung tujuan, bukan hanya skor.



Gambar 6.1. Feature selection mempertahankan fitur asli; PCA membentuk komponen baru.

Aspek	Feature Selection	Feature Extraction (mis. PCA)
Apa yang dilakukan?	Memilih sebagian fitur asli.	Membentuk fitur baru dari kombinasi fitur asli.
Nama fitur setelah proses	Tetap: study_hours, prior_score, dst.	Berubah: PC1, PC2, dst.
Interpretabilitas	Umumnya lebih tinggi.	Umumnya menurun karena satu PC memuat banyak fitur.
Reduksi dimensi	Ya, dengan membuang kolom.	Ya, dengan proyeksi ke ruang berdimensi lebih kecil.
Risiko utama	Fitur penting dapat terbuang.	Informasi kecil tetapi bermakna dapat hilang; makna fitur tidak langsung.
Cocok ketika	Butuh model/analisis yang mudah dijelaskan dan fitur asli penting.	Banyak fitur saling berkorelasi, visualisasi/kompresi dibutuhkan.

6.4 Pendekatan Feature Selection

Pendekatan	Cara kerja	Kelebihan	Risiko
Filter	Menilai fitur dengan statistik sebelum model, misalnya correlation atau mutual information.	Cepat dan relatif model-agnostic.	Sering mengabaikan interaksi dan harus berada dalam CV.
Wrapper	Mencoba subset fitur berdasarkan kinerja model.	Dapat menangkap hubungan dengan model tertentu.	Mahal dan mudah overfit pada validation kecil.
Embedded	Seleksi terjadi saat training, misalnya koefisien L1 atau importance pohon.	Terintegrasi dengan model.	Interpretasi bergantung asumsi dan bias model.

Semua seleksi berbasis data harus dilakukan di dalam cross-validation. Jika fitur dipilih menggunakan seluruh data lalu kinerja dilaporkan melalui cross-validation, validation folds telah memengaruhi pemilihan fitur. Pipeline memastikan selector di-fit ulang pada training fold.

6.5 Contoh Feature Selection dengan Perhitungan Manual

Langkah 1 — Menghapus fitur tanpa variasi

Untuk `constant_feature = [1, 1, 1, 1, 1]`, rata-rata = 1. Variance populasi:

Var(X) = (Σ (x_i - x̄)^2) / n = 0 / 5 = 0

Karena variance = 0, fitur ini tidak membedakan satu mahasiswa dari mahasiswa lain. Fitur aman dihapus untuk tujuan analisis variasi.

Langkah 2 — Mengukur relevansi terhadap target dengan korelasi Pearson

Gunakan `study_hours = [1,2,3,4,5]` dan `final_score = [55,60,72,78,90]`.

i	x	y	x-x̄	y-ȳ	(x-x̄)(y-ȳ)	(x-x̄)^2	(y-ȳ)^2
1	1	55	-2	-16	32	4	256
2	2	60	-1	-11	11	1	121
3	3	72	0	1	0	0	1
4	4	78	1	7	7	1	49
5	5	90	2	19	38	4	361
Σ					88	10	788

x̄ = 3 dan ȳ = 71. Maka:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

r = 88 / sqrt(10 x 788) = 0.9913

Nilai |r| mendekati 1 menunjukkan hubungan linear yang sangat kuat pada contoh kecil ini. Namun korelasi tidak membuktikan kausalitas, dan threshold tidak boleh dipakai secara mekanis tanpa pengetahuan domain.

Langkah 3 — Mendeteksi redundansi antarfitur

`practice_count = [2,4,6,8,10]` selalu dua kali `study_hours`. Korelasi Pearson antara keduanya adalah r = 1.000. Artinya, untuk contoh ini, kedua kolom membawa pola variasi yang sama. Kita dapat mempertahankan `study_hours` karena lebih sederhana dan langsung bermakna.

Fitur	Variance / korelasi relevan	Keputusan contoh	Alasan
constant_feature	variance = 0	Hapus	Tidak membedakan observasi.
study_hours	corr(target) = 0.991	Pertahankan	Sangat relevan dan mudah dijelaskan.
practice_count	corr(study_hours) = 1.000	Hapus sebagai redundan	Informasinya sudah diwakili study_hours.

Fitur	Variance / korelasi relevan	Keputusan contoh	Alasan
attendance_pct	corr(target) ≈ 0.383	Pertimbangkan pertahankan	Hubungan lebih lemah; domain pendidikan dapat tetap menganggapnya relevan.
random_noise	corr(target) ≈ 0.085	Hapus pada contoh	Sangat lemah dan sengaja dibuat acak.

Apa pengaruh feature selection?

Sebelum	Sesudah seleksi contoh	Pengaruh
5 fitur input	2 fitur dipertahankan: study_hours + attendance_pct	Dimensi turun 60%.
Ada fitur konstan	Fitur konstan dihapus	Tidak ada ruang fitur terbuang untuk nilai yang sama.
Ada fitur redundan	practice_count dihapus	Mengurangi duplikasi informasi.
Nama fitur asli tersedia	Nama fitur asli tetap tersedia	Interpretabilitas relatif tinggi.
Semua sinyal dipertahankan	Sinyal lemah bisa terbuang	Perlu sensitivity analysis dan domain review.

6.5 Feature Extraction dan Intuisi PCA

Beberapa metode feature extraction yang dipakai

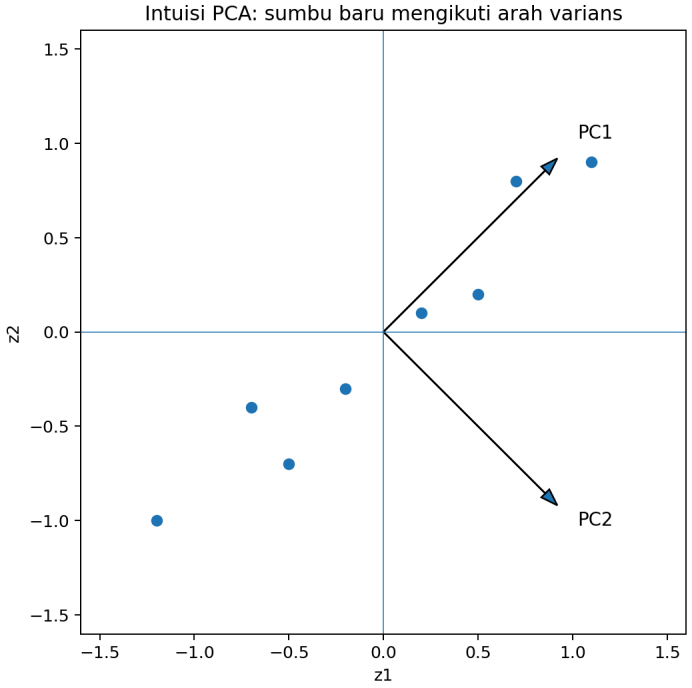
Keluarga/metode	Ide representasi baru	Contoh penggunaan
PCA	Kombinasi linear yang menangkap variance terbesar.	Data tabular numerik berkorelasi.
ICA	Mencari komponen yang sebisa mungkin independen.	Pemisahan sumber/sinyal.
Random Projection	Memproyeksikan data ke kombinasi linear acak berdimensi lebih rendah.	Kompresi data sangat tinggi dimensi.
FFT/Wavelet/MFCC	Mengubah sinyal mentah menjadi representasi frekuensi/karakteristik.	Sensor, audio, getaran.
TF-IDF / embedding	Mengubah teks/token menjadi vektor numerik.	NLP/text mining.
Autoencoder / learned embedding	Jaringan belajar representasi laten yang lebih ringkas.	Citra, sinyal, data kompleks.

Catatan istilah

Feature engineering adalah istilah payung yang lebih luas. Membuat rasio, agregasi, atau fitur domain baru sering disebut feature engineering.

Principal component analysis (PCA) mencari arah baru yang saling ortogonal. Komponen pertama menangkap varians terbesar; komponen kedua menangkap varians terbesar yang tersisa dengan syarat tegak lurus terhadap komponen pertama, dan seterusnya. PCA tidak menggunakan target, sehingga komponen dengan varians besar belum tentu paling prediktif.

Pada gambar 6.2 terlihat bahwa sumbu x dan y bukan satu-satunya cara membaca posisi titik. Kita dapat memutar sumbu koordinat sehingga sumbu pertama mengikuti arah awan yang paling panjang. Arah baru itu disebut PC1. Arah tegak lurus berikutnya disebut PC2.



Gambar 6.2. Arah PC1 mengikuti sebaran data terbesar; PC2 tegak lurus terhadap PC1

Alur PCA

1. Center/standardize fitur: samakan pusat dan, bila skala berbeda, samakan skala.
2. Bentuk covariance matrix atau correlation matrix: ringkas bagaimana fitur bervariasi bersama.
3. Cari eigenvalue dan eigenvector: eigenvector = arah PC; eigenvalue = besarnya variance sepanjang arah itu.
4. Urutkan dari eigenvalue terbesar: PC1 selalu memiliki eigenvalue terbesar.
5. Hitung explained variance ratio: bagian variance total yang dijelaskan tiap PC.
6. Project setiap observasi: score = dot product data standardized dengan loading/eigenvector.
7. Pilih k PC: semakin sedikit PC, semakin ringkas tetapi potensi information loss semakin besar.

Mengapa standardisasi biasanya dilakukan sebelum PCA?

PCA sensitif terhadap skala. Fitur dengan satuan 0–100 dapat memiliki variance numerik jauh lebih besar daripada fitur 0–10 sehingga mendominasi komponen. Sebelum PCA, fitur biasanya distandardisasi agar fitur berskala besar tidak mendominasi arah. Standardisasi mengubah setiap fitur menjadi z-score.

$$z = (x - \text{mean}) / \text{standard deviation}$$

Sesudah standardisasi, setiap fitur mempunyai pusat sekitar 0 dan skala yang sebanding.

Worked Example PCA 2D — hitung manual

Anggap dua fitur sudah distandardisasi sehingga correlation/covariance matrix-nya adalah:

```
R = [[1.0, 0.8], [0.8, 1.0]]
```

Eigenvalue tidak muncul tiba-tiba. Nilainya dicari dari persamaan det(R - λI)=0:

$$(1 - \lambda)^2 - (0.8 \times 0.8) = 0$$

Sehingga (1 - λ)^2 = 0.64, maka 1 - λ = ±0.8. Diperoleh:

$$\lambda 1 = 1.8 \quad \text{dan} \quad \lambda 2 = 0.2$$

Dari hasil eigenvalue diperoleh 1.8 dan 0.2. Karena PCA mengurutkan principal component berdasarkan variance terbesar, eigenvalue 1.8 menjadi PC1 dan eigenvalue 0.2 menjadi PC2. PC1 menjelaskan 90% total variance, sedangkan PC2 hanya 10%

Dari eigenvalue ke loading/eigenvector

Eigenvalue mengatakan “berapa besar varians”.Sedangkan eigenvector mengatakan “ke arah mana varians tersebut berada”. Definisi eigenvector adalah:

$$Rv = \lambda v,$$
$$\lambda v = \lambda I v$$
$$(R - \lambda I)v = 0$$

Dibaca:
Ketika matriks R dikalikan dengan suatu vektor v, hasilnya mempunyai arah yang sama dengan v, hanya panjangnya berubah sebesar faktor λ. v adalah eigenvector yang dicari,dengan v_1 adalah kontribusi/koefisien fitur pertama, sedangkan v_2 adalah kontribusi fitur kedua.

Untuk λ1=1.8, persamaan (R - 1.8I)v = 0 menghasilkan hubungan $v_1 = v_2$

$$||v|| = \sqrt{1^2 + 1^2}$$

Setelah dinormalisasi agar panjang vektor = 1, arah PC1 adalah kira-kira [0.707, 0.707] = $[1/\sqrt{2}, 1/\sqrt{2}]$. Untuk λ2=0.2, diperoleh $v_1 = -v_2$ sehingga arah PC2 dapat ditulis [0.707, -0.707].

Komponen	Eigenvalue	Loading/eigenvector	Arti sederhana
PC1	1.8	[0.707, 0.707]	Kedua fitur bergerak bersama; PC1 seperti "gabungan searah".
PC2	0.2	[0.707, -0.707]	Menangkap perbedaan antara fitur pertama dan kedua.

Projection: mengubah satu observasi menjadi score PC

Misalkan satu mahasiswa setelah standardisasi mempunyai z=[1.0, 0.5]. Artinya fitur pertama 1 standar deviasi di atas rata-rata, fitur kedua 0.5 standar deviasi di atas rata-rata.

Projection menjawab pertanyaan: Jika titik $(1.0, 0.5)$ dilihat dari sumbu PC1, koordinatnya berapa?

PC1 score = 1.0(0.707) + 0.5(0.707) = 1.0605

Angka tersebut adalah koordinat mahasiswa pada sumbu PC1..

PC2 score = 1.0(0.707) + 0.5(-0.707) = 0.3535

*Angka tersebut adalah **koordinat mahasiswa pada sumbu PC2.***

Dengan demikian, data yang semula: [1.0,0.5]

dinyatakan ulang menjadi:[1.0605,0.3535]

Inilah feature extraction.

Apa arti reconstruction dan information loss?

Reconstruction digunakan untuk menjawab: Seberapa dekat data yang telah direduksi dengan data asli?

Misalnya kita memutuskan hanya menyimpan PC1 karena PC1 menjelaskan sebagian besar variance.

Kita punya: $PC1\ score\ =\ 1.0605$

dan arah PC1: $v_1\ =\ [0.707, 0.707]$

Untuk kembali ke ruang fitur asli: $\hat{z} = PC1\ \times v_1$

Jika hanya PC1 disimpan, kita merekonstruksi pendekatan fitur asal dari PC1 saja:

$$\hat{z} = 1.0605 \times [0.707, 0.707] \approx [0.75, 0.75]$$

Nilai standardized asli [1.00, 0.50], sedangkan hasil rekonstruksi [0.75,0.75]. Selisih [0.25,-0.25] adalah error karena PC2 dibuang.

$$\text{MSE} = (0.25^2 + (-0.25)^2) / 2 = 0.0625$$

Semakin kecil reconstruction error, semakin dekat representasi tereduksi terhadap data standardized asal.

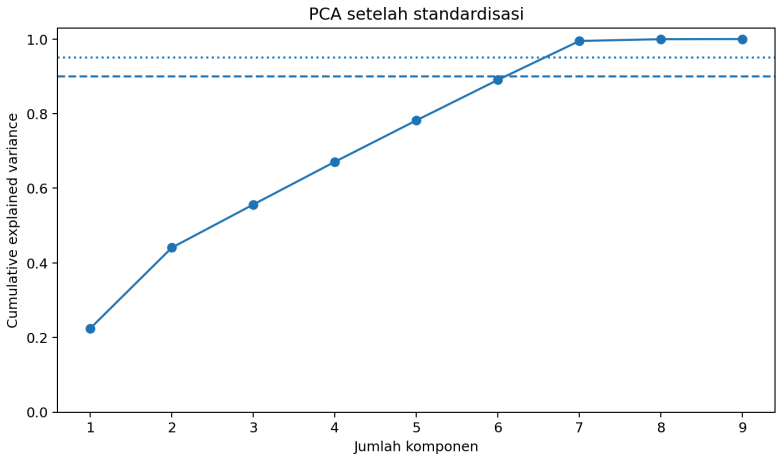
Ketika PC2 dibuang, titik tidak lagi boleh berada di seluruh bidang 2D. Titik tersebut hanya boleh berada di garis PC1. Titik terdekat pada garis PC1 terhadap: $(1, 0.5)$ adalah:[0.75,0.75]. Itulah makna projection.

Jika PC1 dan PC2 sama-sama dipertahankan, rekonstruksi menjadi z=PC1×v_1 + PC2×v_2 = [1.00,0.50]. Jadi, pada contoh 2D ini, loss bukan karena "PCA merusak data", melainkan karena kita sengaja menyimpan hanya satu dari dua komponen.

6.6 Explained Variance dan Jumlah Komponen

Explained variance ratio (EVR) menunjukkan proporsi total variance data yang direpresentasikan oleh setiap principal component. EVR dihitung dari eigenvalue suatu komponen dibagi jumlah seluruh eigenvalue. Sebagai contoh, jika PCA menghasilkan eigenvalue 1.8 dan 0.2, total variance adalah 2.0. Dengan demikian PC1 memiliki EVR (1.8/2=90%), sedangkan PC2 memiliki EVR (0.2/2=10%).

Cumulative explained variance diperoleh dengan menjumlahkan EVR secara bertahap dan dapat digunakan sebagai salah satu dasar menentukan jumlah komponen yang dipertahankan. Jika ambang ditetapkan 90%, maka pada contoh tersebut cukup digunakan PC1; jika ambang 95%, PC1 saja tidak cukup sehingga PC2 juga harus dipertahankan. Ambang 90%, 95%, atau nilai lainnya bukan aturan universal, melainkan trade-off antara pengurangan dimensi dan information loss. Perlu diingat bahwa explained variance tidak sama dengan accuracy atau predictive information karena PCA tidak menggunakan target. Variance kecil juga dapat menyimpan pola penting bagi subgroup tertentu.



Gambar 6.3. Contoh cumulative explained variance pada dataset praktikum setelah standardisasi.

6.6 Membandingkan Dampak Selection dan PCA

Kriteria	Data awal praktikum	Feature Selection (contoh threshold |r|>=0.20 + redundansi >0.90)	PCA 90% setelah standardisasi
Dimensi	10 fitur numerik (termasuk 1 konstan)	4 fitur asli: study_hours, prior_score, attendance_pct, screen_time	7 komponen dari 9 fitur nonkonstan
Nama fitur	Langsung	Tetap langsung	Berubah menjadi PC1...PC7
Memori tabel numerik	≈ 240 KB	≈ 96 KB	Matriks 7 kolom; lebih kecil dari 9 kolom
Interpretabilitas	Tinggi	Tinggi	Lebih rendah; perlu membaca loadings
Informasi yang hilang	Belum ada	Sinyal lemah dapat terbuang (mis. sleep_hours)	Variance kecil dibuang; rekonstruksi tidak persis
Kapan menarik?	Baseline	Ketika fitur asli penting untuk audit/penjelasan	Ketika kompresi/visualisasi lebih penting dan korelasi antarf fitur tinggi

6.7 Pertanyaan

1. Variance threshold: fitur A = [4,4,4,4,4] dan fitur B = [1,2,3,4,5]. Hitung variance populasi keduanya. Fitur mana yang jelas dapat dihapus jika threshold variance = 0?
2. Korelasi relevansi: gunakan x = study_hours [1,2,3,4,5] dan y = final_score [55,60,72,78,90]. Dengan tabel deviasi yang tersedia pada worked example, hitung kembali r Pearson sampai 4 angka desimal dan interpretasikan.

3. Redundansi: fitur C = [2,4,6,8,10] dan B = [1,2,3,4,5]. Tanpa menghitung panjang, jelaskan mengapa korelasinya +1 dan pilih salah satu yang lebih mudah dipertahankan dalam konteks jam belajar.
4. PCA: diberikan eigenvalue $\lambda 1=1.8$ dan $\lambda 2=0.2$. Hitung explained variance masing-masing PC dan cumulative variance jika hanya PC1 dipertahankan.
5. Projection: untuk z=[1.0,0.5] dan loading PC1=[0.707,0.707], hitung PC1 score. Rekonstruksi z menggunakan PC1 saja dan hitung MSE terhadap z asli.
6. Analisis keputusan: jika feature selection menghasilkan 4 fitur asli, sedangkan PCA 90% menghasilkan 7 PC dari 9 fitur, metode mana yang lebih baik? Jawaban harus mempertimbangkan tujuan, bukan hanya jumlah kolom.

6.8 Ringkasan

- Feature selection mempertahankan fitur asli; feature extraction membentuk representasi baru.
- Filter, wrapper, dan embedded berbeda dalam cara, biaya, serta ketergantungan pada model.
- PCA mencari arah varians besar, bukan otomatis arah yang paling relevan terhadap target.
- Explained variance harus dibaca bersama metrik tugas dan subgroup.
- Interpretabilitas dan sensitivity analysis membantu menguji kewajaran, stabilitas, dan batas penggunaan.

Daftar Pustaka

Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems (3rd ed.; copyright 2023). O'Reilly Media.

James, G., Witten, D., Hastie, T., Tibshirani, R., & Taylor, J. (2023). An Introduction to Statistical Learning with Applications in Python. Springer.

Molnar, C. (2019). Interpretable Machine Learning: A Guide for Making Black Box Models Explainable. Leanpub. Berkas sumber yang digunakan adalah versi 21 Februari 2019, lisensi CC BY-NC-SA 4.0.

